

知识图谱综述——表示、构建、推理与知识超图理论

田玲^{1*}, 张谨川¹, 张晋豪², 周望涛¹, 周雪²

(1. 电子科技大学 计算机科学与工程学院, 成都 611731; 2. 电子科技大学 信息与软件工程学院, 成都 610054)

(* 通信作者电子邮箱 lingtian@uestc.edu.cn)

摘要: 针对知识图谱(KG)在知识驱动的人工智能研究中发挥的强大支撑作用, 分析并总结了现有知识图谱和知识超图技术。首先, 从知识图谱的定义与发展历程出发, 介绍了知识图谱的分类和架构; 其次, 对现有的知识表示与存储方式进行了阐述; 然后, 基于知识图谱的构建流程, 分析了各类知识图谱构建技术的研究现状。特别是针对知识图谱中的知识推理这一重要环节, 分析了基于逻辑规则、嵌入表示和神经网络的三类典型的知识推理方法。此外, 以异构超图引出知识超图的研究进展, 并提出三层架构的知识超图, 从而更好地表示和提取超关系特征, 实现对超关系数据的建模及快速的知识推理。最后, 总结了知识图谱和知识超图的典型应用场景并对未来的研究作出了展望。

关键词: 知识图谱; 图谱构建; 知识推理; 知识超图

中图分类号: TP182 **文献标志码:** A

Knowledge graph survey: representation, construction, reasoning and knowledge hypergraph theory

TIAN Ling^{1*}, ZHANG Jinchuan¹, ZHANG Jinhao², ZHOU Wangtao¹, ZHOU Xue²

(1. School of Computer Science and Engineering, University of Electronic Science and Technology of China, Chengdu Sichuan 611731, China;

2. School of Information and Software Engineering, University of Electronic Science and Technology of China, Chengdu Sichuan 610054, China)

Abstract: Knowledge Graph (KG) strongly support the research of knowledge-driven artificial intelligence. Aiming at this fact, the existing technologies of knowledge graph and knowledge hypergraph were analyzed and summarized. At first, from the definition and development history of knowledge graph, the classification and architecture of knowledge graph were introduced. Second, the existing knowledge representation and storage methods were explained. Then, based on the construction process of knowledge graph, several knowledge graph construction techniques were analyzed. Specifically, aiming at the knowledge reasoning, an important part of knowledge graph, three typical knowledge reasoning approaches were analyzed, which are logic rule-based, embedding representation-based, and neural network-based. Furthermore, the research progress of knowledge hypergraph was introduced along with heterogeneous hypergraph. To effectively present and extract hyper-relational characteristics and realize the modeling of hyper-relation data as well as the fast knowledge reasoning, a three-layer architecture of knowledge hypergraph was proposed. Finally, the typical application scenarios of knowledge graph and knowledge hypergraph were summed up, and the future researches were prospected.

Key words: Knowledge Graph (KG); graph construction; knowledge reasoning; knowledge hypergraph

0 引言

随着计算机科学相关领域研究的不断深入, 人工智能的研究重心由感知智能转向认知智能。专家系统和语义网络作为认知智能的早期代表, 提出“将知识引入人工智能领域”, 在某些特定领域具备一定的问题解决能力, 但仍存在规模较小、自动化构建能力不足、知识获取困难等一系列问题。

知识图谱(Knowledge Graph, KG)的出现, 改变了传统的知识获取模式, 将知识工程“自上而下”方式转变为挖掘数据、抽取知识的“自下而上”方式。经过长期的理论创新与实践探索, 知识图谱已经具备体系化的构建与推理方法。然而, 对于实体关系, 知识图谱虽然有较强的建模能力, 但难以表达普遍

存在的多元关系。知识超图通过引入超边关系, 能够完整表达各种复杂的关系类型, 得到学术界和工业界的高度关注。此外, 知识图谱和知识超图能够结合深度学习(Deep Learning, DL)等人工智能技术, 实现高效推理。

1 知识图谱基本概念

本章将从知识图谱定义引入, 介绍知识图谱的发展历程、常见的知识图谱分类以及知识图谱的逻辑架构。

1.1 知识图谱定义与发展历程

知识图谱在维基百科中的定义是: 使用语义检索, 从多种来源收集信息, 以提高搜索质量的知识库^[1]。本质上, 知识图谱是真实世界中存在的各种实体、概念及其关系构成的语义

收稿日期: 2021-04-26; 修回日期: 2021-06-03; 录用日期: 2021-06-16。

作者简介: 田玲(1981—), 女, 四川成都人, 教授, 博士, CCF会员, 主要研究方向: 知识驱动的人工智能、事件预测; 张谨川(1998—), 男, 江西鹰潭人, 博士研究生, 主要研究方向: 时间序列分析、知识图谱; 张晋豪(1998—), 男, 重庆人, 博士研究生, 主要研究方向: 知识图谱、知识图谱问答; 周望涛(1997—), 男, 重庆人, 博士研究生, 主要研究方向: 社交媒体分析、事件预测; 周雪(1995—), 女, 四川成都人, 博士研究生, 主要研究方向: 知识图谱、表示学习。

网络图,用于形式化地描述真实世界中各类事物及其关联关系。

如图1所示,1965年,斯坦福大学的E. A. Feigenbaum提出专家系统(Expert System, ES)的概念,基于知识进行决策,使人工智能的研究从推理算法主导转变为知识主导。

之后,在1968年,M. R. Quillian提出语义网络(Semantic Network, SN)的知识表达模式,用相互连接的节点和边来表示知识,知识库(Knowledge Base, KB)的构建和知识表示(Knowledge Representation, KR)方法成为研究的热点。

1977年,在第五届国际人工智能联合会议上,E. A. Feigenbaum提出知识工程(Knowledge Engineering, KE)概念,以知识为处理对象,基于人工智能的原理、方法和技术,研究

如何用计算机表示知识,进行问题的求解。

1989年,Tim Berners-Lee发明了万维网(World Wide Web, WWW),并于1998年提出语义网(Semantic Web, SW)概念,将传统人工智能的发展与万维网结合,以资源描述框架(Resource Description Framework, RDF)为基础,在万维网中应用知识表示与推理方法。

2012年,Google提出知识图谱概念^[2]。不同于传统专家系统和知识工程主要依靠手工获取知识的方式,知识图谱作为新时代的知识工程技术,以RDF三元组和属性图表示知识,数据规模巨大,需要使用机器学习(Machine Learning, ML)、自然语言处理(Natural Language Processing, NLP)等技术进行自动化的图谱构建。




图1 知识图谱发展历程

Fig. 1 Development history of knowledge graph

1.2 知识图谱分类

本节将分别介绍早期知识库、开放知识图谱、中文常识知识图谱和领域知识图谱等。

1.2.1 早期知识库

早期知识库通常由相关领域专家人工构建,准确率和利用价值高,但存在构建过程复杂、需要领域专家参与、资源消耗大、覆盖范围小等局限。典型的早期知识库包含WordNet^[3]、ConceptNet^[4]等。

WordNet是由普林斯顿大学认知科学实验室从1985年开始开发的词典知识库,主要用于词义消歧。WordNet主要定义了名词、动词、形容词和副词之间的语义关系。例如名词之间的上下位关系中,“Canine”是“Dog”的上位词。WordNet包含超过15万个词和20万个语义关系。

ConceptNet是一个常识知识库,源于麻省理工学院媒体实验室在1999年创立的OMCS(Open Mind Common Sense)项目。ConceptNet采用了非形式化、类似自然语言的描述,侧重于词与词之间的关系。ConceptNet以三元组形式的关系型知识构成,已经包含近2 800万个关系描述。

1.2.2 开放知识图谱

开放知识图谱类似于开源社区的数据仓库,允许任何人在遵循开源协议和开放性原则的前提下进行自由的访问、使用、修改和共享,典型代表为Freebase^[5]、Wikidata^[6]等。

Freebase是MetaWeb从2005年开始研发的开放共享的大规模链接知识库。Freebase作为Google知识图谱的数据来源之一,包含多种话题和类型的知识,包括人类、媒体、地理位置等信息。Freebase基于RDF三元组模型,底层采用图数据库存储,包含约4 400万个实体,以及29亿相关的事实。

Wikidata是一个开放、多语言的大规模链接知识库,由维基百科从2012年开始研发。Wikidata以三元组的形式存储知识条目,其中每个三元组代表一个条目的陈述,例如“Beijing”的条目描述为“(Beijing, isTheCapitalOf, China)”。Wikidata包含超过2 470万个知识条目。

1.2.3 中文常识知识图谱

与英文百科数据相比,中文百科数据结构更为多样,语义

内涵更为丰富,且包含的结构化、半结构化数据有限,为知识图谱的构造提出了更大的挑战。当前,中文常识图谱的主要代表为Zhishi. me^[7]、CN-DBpedia^[8]等。

Zhishi. me采用与DBpedia类似的方法,从百度百科、互动百科和维基百科中提取结构化知识,并通过固定的规则将它们之间的等价实体链接起来。Zhishi. me包含超过1 000万个实体和1.25亿个三元组。

CN-DBpedia是一个大规模的中文通用知识图谱,由复旦大学于2015年开始研发。CN-DBpedia主要从中文百科类网站(如百度百科、互动百科、中文维基百科等)中提取信息,并且对提取的知识进行整合、补充和纠正,极大地提高了知识图谱的质量。CN-DBpedia包含940万个实体和8 000万个三元组。

1.2.4 领域知识图谱

领域知识图谱面向军事、公安、交通、医疗等特定领域,用于复杂的应用分析或辅助决策,具有专家参与度高、知识结构复杂、知识质量要求高、知识粒度细等特点。

例如“星河”知识图谱^[9],作为一个军事知识图谱,具有暗网数据、互联网数据、传统数据库、军事书籍等多种数据来源。“星河”知识图谱按军事事件类型和实体类型进行划分,包括88个国家和6大作战空间的武器装备,共10万余装备实体数据、330个军事本体类别。

其余典型的领域知识图谱还包括IBM Watson Health医疗知识图谱^[10]、海致星图金融知识图谱^[11]、海信“交管云脑”交通知识图谱^[12]等。

1.3 知识图谱架构

知识图谱在逻辑架构层面可分为模式层和数据层,如表1所示。

表1 知识图谱逻辑结构

Tab. 1 Logical structure of knowledge graph

逻辑结构层次	主要内容	示例
模式层	知识类的数据模型	概念及关系
数据层	具体的数据信息	事实三元组

1.3.1 知识图谱模式层

模式层在数据层之上,是知识图谱的核心。主要内容为知识的数据结构,包括实体(Entity)、关系(Relation)、属性

(Attribute)等知识类的层次结构和层级关系定义,约束数据层的具体知识形式。在复杂的知识图谱中,一般通过额外添加规则或公理表示更复杂的知识约束关系。

1.3.2 知识图谱数据层

数据层是以事实(Fact)三元组等知识为单位,存储具体的数据信息。知识图谱一般以三元组 $G = \{E, R, F\}$ 的形式表示。其中, E 表示实体集合 $\{e_1, e_2, \dots, e_E\}$, 实体 e 是知识图谱中最基本的组成元素,指代客观存在并且能够相互区分的事物,可以是具体的人、事、物,也可以是抽象的概念。 R 表示关系集合 $\{r_1, r_2, \dots, r_R\}$, 关系 r 是知识图谱中的边,表示不同实体间的某种联系。 F 表示事实集合 $\{f_1, f_2, \dots, f_F\}$, 每一个事实 f 又被定义为一个三元组 $(h, r, t) \in f$ 。其中, h 表示头实体, r 表示关系, t 表示尾实体。例如,事实的基本类型可以用三元组表示为(实体, 关系, 实体)和(实体, 属性, 属性值)等。

在事实中,实体一般指特定的对象或事物,如具体的某个国家或某本书籍等;关系表示实体间的某种外在联系,属性和属性值表示一个实体或概念特有的参数名和参数值。

(实体, 关系, 实体)三元组可以表示为有向图结构,以单向箭头表示非对称关系,以双向箭头表示对称关系。具体示例如图2所示,实体“Arthur”与实体“Carl”间存在“ColleagueOf(同事)”对称关系;实体“Carl”与实体“Barry”存在“HasChild(父子)”非对称关系。



图2 三元组示例1

Fig. 2 Triple example 1

(实体, 属性, 属性值)三元组可以表示为有向图结构,单向箭头表示实体的属性,由实体指向属性值。具体示例如图3所示,实体“Barry”的属性有“DateOfBirth(出生日期)”等。其中,“DateOfBirth”属性值为“2012.12.31”。



图3 三元组示例2

Fig. 3 Triple example 2

总体而言,知识图谱可以看作是事实的结构化表征,包括事实的实体、关系、属性以及语义描述。

2 知识表示与存储

知识表示与存储是知识图谱构建、管理和应用的基础。现代知识图谱基于海量的互联网数据,规模日益增长,对知识

的高效表示和有效存储提出了新的挑战。本章将分析介绍现有的知识表示方法与存储方式。

2.1 知识表示

知识图谱中,知识表示是一种对知识的描述方式,利用信息技术将真实世界中的海量信息转化为符合计算机处理模式的结构化数据。

如表2所示,早期的知识表示方法有一阶逻辑(First-Order Logic, FOL)^[13]、霍恩逻辑(Horn Logic, HL)^[14]、语义网络(SN)^[15]、产生式规则(Production Rules, PR)^[16]、框架系统(Frame Systems, FS)^[17]、脚本理论(Script Theory, ST)^[18]等。随着互联网络的发展和语义网SW的提出,需要用于面向语义网知识表示的标准语言。因此,万维网联盟(W3C)提出了XML(eXtensible Markup Language)^[19]、RDF^[20]、RDFS(RDF Schema)^[21]和OWL(Web Ontology Language)^[22]描述语言。

XML作为最早的语义网描述语言,以文档为单位表示知识,可以用于标记数据和定义数据类型。通过XML,用户可以自由地设计元素和属性标签;但由于不能显式地定义标签的语义约束,灵活、个性化的标签设置导致XML通用性差。

RDF提供一个统一的标准以“主体(Subject)-谓词(Predicate)-宾语(Object)”的SPO三元组来描述实体和资源。RDF可以表示为有向图结构,其中谓词作为边,可以是连接主体和宾语的关系或是连接主体和数据的属性等;但RDF中缺乏对类和属性的明确定义,抽象能力不足。

RDFS可以看作RDF的拓展,在RDF的基础上,对RDF中的类、属性及关系提供了模式定义,为RDF提供了数据模型和简单的约束规则;但RDFS只能声明子类关系,无法对互斥类、多个类或实例进行声明。

OWL则是在RDFS的基础上,针对复杂场景,添加了额外的预定义词汇来描述资源,如可以声明数据的等价性、属性的传递性、互斥性、函数性、对称性等。

然而,这些传统的知识表示方法都是基于符号逻辑,能够刻画显式、离散的知识,却不能表示真实世界中大量不易于用符号逻辑解释的知识,难以有效挖掘分析知识实体间的语义关系。

近年来,基于深度学习的知识表示学习(Knowledge Representation Learning, KRL)在语音识别、图像分析和自然语言处理领域得到广泛关注。知识表示学习面向知识库实体和关系,通过将研究对象(如三元组)中的语义信息投影到稠密的低维向量空间,实现对实体和关系语义信息的分布式表示,能够高效地计算实体、关系间的复杂语义关系,易于深度学习模型的集成。

表2 早期知识表示方法对比

Tab. 2 Comparison of early knowledge representation methods

知识表示方法	优点	缺点
一阶逻辑	拥有通用的逻辑和推理规则;可以精确表达知识;和自然语言表现方式相近;易于实现	推理效率低;灵活性差;无法表示不确定性知识
霍恩逻辑	结构性强;有形式化语法语义和相关推理规则;可拓展性强;易于实现	表达能力有限;无法表示不确定性知识
语义网络	结构性强;表示直观;具备事物间语义联想性	无形式化语法;无形式化语言;难以表示复杂深层知识
产生式规则	格式固定;形式简单;知识库与推理机分离,易于修改解释;符合自然语言思维,能表示不确定性知识	难以扩展;规则选择效率低;控制策略不灵活;知识表示形式单一
框架系统	结构性强;知识描述全面	适应性差;构建成本高;质量要求高;复杂度高;无法表示不确定性知识
脚本理论	小领域内对事件步骤和时序关系刻画细致;适用于表达顺序性事件或预先构想的特定知识	表示范围窄;无法描述元素基本属性;难以描述多变事件的发展可能方向

2.2 知识存储

随着信息时代数据量的爆炸式增长,知识图谱的规模日益增大,对知识的管理和存储提出了更高的要求。

知识存储的目的是确定合理高效的知识图谱存储方式。现有研究中,大部分知识图谱都是基于图的数据结构,如表3所示,主要的存储方式有三种:RDF数据库、传统关系型数据库(Relational Database, RDB)存储和图数据库(Graph Database, GDB)存储。

表3 知识存储方式对比

Tab. 3 Comparison of knowledge storage methods

知识存储方式	优点	缺点
RDF 数据库	图结构描述直观;	设计不灵活;
	语义表达能力强;	占用存储空间大;
	易于数据共享发布	查询搜索效率低
关系型数据库	存储效率高;一般查询效率高	关联查询效率低;
图数据库	深度查询效率高;多跳查询效率高	难以实时查询 资源消耗大

2.2.1 RDF 数据库

RDF 数据库存储就是将组成 RDF 数据集的三元组抽象为图的形式存储数据。其优点是图结构描述直观,可以最大限度保持 RDF 数据的语义信息,易于数据的共享和发布;但是 RDF 不包含实体的属性信息、所需存储空间大,没有图查询相应引擎,导致查询和搜索效率低下,且在处理新增数据时需要重构整个图。目前学术界主要的开源 RDF 数据库包括:Jena^[23]、RDF4J^[24]和 gStore^[25]等。

2.2.2 关系型数据库

RDB 发展历史久远,理论体系成熟,是知识图谱存储的常用方式。RDB 使用三元组、水平表、属性表、垂直划分和六重索引等建表方式存储知识三元组,知识存储和查询效率都比较高;但是在进行深度的关联关系查询或多跳查询时效率较低,且难以处理实时的关系查询。目前主流的开源 RDB 有 PostgreSQL^[26]和 MySQL^[27]等。

2.2.3 图数据库

GDB 是一种非关系型数据库,基于 GDB 的存储是目前知识存储的主流方式。其优点是以节点和边表示数据,明确地列出了数据节点间的依赖关系,具有完善的图查询语言且支持各种图挖掘算法,在深度关联查询速度上优于传统的关系型数据库;但由于分布式存储特性,资源消耗大。典型的 GDB 有 Neo4j^[28]、JanusGraph^[29]和 HugeGraph^[30]等。

3 知识图谱构建技术

构建大规模、高质量的通用知识图谱或基于行业数据的领域知识图谱,实现大量知识的准确抽取和快速聚合,需要运用多种高效的知识图谱构建技术。

如图4所示,知识图谱是通过知识抽取(Knowledge Extraction, KE)、知识融合(Knowledge Fusion, KF)、知识加工(Knowledge Processing, KP)和知识更新(Knowledge Update, KU)等构建技术,从原始数据(包括结构化数据、半结构化数据和非结构化数据)和外部知识库中抽取知识事实。根据知识的语义信息进行知识的融合、加工,再通过知识更新技术保障知识图谱的时效性,最终得到完整的知识图谱。本章将对这些构建技术及相关方法进行阐述。

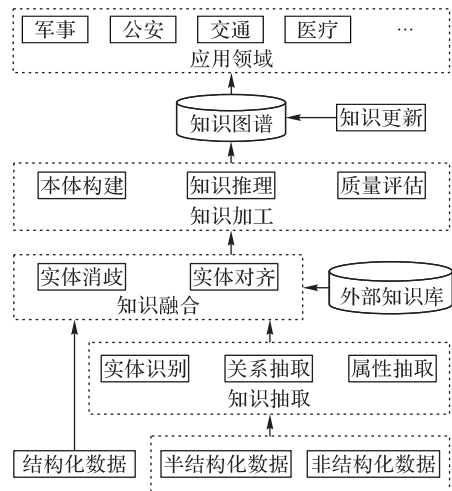


图4 知识图谱构建技术流程

Fig. 4 Flowchart of knowledge graph construction technique

3.1 知识抽取

知识抽取是知识图谱构建的首要任务,通过自动化或半自动化的知识抽取技术,从原始数据中获得实体、关系及属性等可用知识单元,为知识图谱的构建提供知识基础。

早期知识抽取主要是基于规则的知识抽取,通过人工预先定义的知识抽取规则,实现从文本中抽取知识的三元组信息;但是这种传统方法主要依赖具备领域知识的专家手工定义规则,当数据量增大时,规则构建耗时长、可移植性差,难以应对数据规模庞大的知识图谱构建。

相比早期基于规则的知识抽取,基于神经网络的知识抽取将文本作为向量输入,能够自动发现实体、关系和属性特征,适用于处理大规模知识,已成为知识抽取的主流方法。本节将以关系抽取(Relation Extraction, RE)为核心,介绍知识抽取的三类主要任务。

3.1.1 实体识别

实体识别即命名实体识别(Named Entity Recognition, NER),是自然语言处理和知识图谱领域的基础任务。其目的是从海量的原始数据(如文本)中准确提取人物、地点、组织等命名实体信息。实体识别的准确率影响了后续的关系抽取等任务,决定了知识图谱构建的质量。

NER方法可分为基于规则、基于统计模型和基于神经网络三类,如表4所示。

表4 命名实体识别方法对比

Tab. 4 Comparison of named entity recognition methods

方法类别	优点	缺点
规则	适用于小规模数据;精度和可靠性较高	大规模应用困难;可移植性差
统计模型	性能较好;通用性强,可移植	依赖特征和语料库;训练时间长
神经网络	自动化识别;所需专家知识少;性能好,优化便捷	网络模型多样;依赖参数设置;可解释性差

其中,早期的NER方法一般是基于规则的方法和基于统计模型的方法。

基于规则的方法通过专家手工构建规则集,将文本等数据与规则集匹配来得到命名实体信息。该方法在处理小规模

的知识图谱时精度较高,但是随着知识图谱规模的增大,规则构建困难,且由于规则基于人工构建,难以进行大规模扩展并应用于不同领域的知识图谱。

基于统计模型的方法将NER作为序列标注问题,以完全或部分标注的语料进行模型训练。常见的统计模型有条件马尔可夫模型(Conditional Markov Model, CMM)^[31]、隐马尔可夫(Hidden Markov Model, HMM)^[32]、条件随机场(Conditional Random Fields, CRF)^[33]和最大熵(Maximum Entropy, ME)^[34]等。基于统计模型的方法在构建一个新的领域知识图谱时需要做的改动较少,通用性强;但是统计模型的状态搜索空间庞大、训练时间长,高度依赖特征选取和语料库,难以从海量数据中发现复杂且隐含的关键特征。

由于深度学习能够自动地从数据中学习复杂的隐藏特征,所需的领域专业知识和经验知识较少,基于神经网络的NER已成为目前主流方法,主要模型有卷积神经网络(Convolutional Neural Network, CNN)和循环神经网络(Recurrent Neural Network, RNN)等。

Collobert等^[35]最先提出使用卷积层提取句子的局部特征并构造全局特征向量。基于这项工作,Strubell等^[36]提出了ID-CNN,相较于传统的CNN,在大量的文本和结构化数据预测中具有更好的性能。Huang等^[37]提出使用长短时记忆网络(Long Short-Term Memory, LSTM)、双向长短时记忆网络(Bidirectional Long Short-Term Memory, Bi-LSTM)等模型进行序列标注,能够有效利用序列的上下文信息。Žukov-Gregorič等^[38]则是在先前研究的基础上,使用多个独立的Bi-LSTM分布计算进行实体识别,减少了参数总数。杨飘等^[39]针对中文NER普遍存在无法表征字的多义性问题,通过嵌入BERT(Bidirectional Encoder Representation from Transformers)预训练语言模型,构建BERT-BiGRU(Bidirectional Gated Recurrent Unit networks)-CRF模型表征语句的特征,有效提升中文NER效果。

此外,还有一些基于神经网络的改进模型,如Lin等^[40]提出了“实体触发器(Entity Trigger, ET)”概念,针对NER问题作出解释性注释,通过触发器匹配网络(Trigger Matching Network, TMN)对ET进行编码,提高实体标记的有效性,减少了NER人工注释的成本。

3.1.2 关系抽取

关系抽取(RE)是知识图谱领域的研究重点,也是知识抽取中的核心内容。通过获取实体之间的某种语义关系或关系的类别,自动识别实体对及联系这一对实体的关系所构成的三元组^[41]。

近年来,RE研究大多是基于神经网络方法,主要包括基于CNN、基于RNN、基于注意力机制(Attention mechanism, ATT)、基于图卷积网络(Graph Convolutional Network, GCN)、基于对抗训练(Adversarial Training, AT)、基于强化学习(Reinforcement Learning, RL)的RE以及实体-关系联合抽取(Joint Entity and Relation Extraction, JERE)。

1) 基于卷积神经网络的关系抽取。

CNN通过将嵌入表示和文本信息等数据组织为类似图像的二维结构,使用卷积核提取特征信息并用于关系抽取。

针对基于统计机器学习的关系抽取方法过度依赖提取的特征质量问题,Zeng等^[42]首次提出使用CNN提取单词和句子级特征,形成特征向量预测关系分类。之后,Nguyen等^[43]提出多窗口CNN研究语料库不平衡情况下的关系抽取。PATMR^[44]使用分段CNN(Piecewise CNN, PCNN)对每个句子编码,挖掘未标记语料库的相互关系,结合实体类型与隐式关系

进行关系抽取。

CNN方法为基于深度学习的关系抽取提供了思路,后续很多基于神经网络的关系抽取方法都利用CNN提取单词和句子的特征。

2) 基于循环神经网络的关系抽取。

RNN可以很好地利用内部的记忆机制处理时序相关信息,适用于处理和表示短语及句子的组合向量。

Socher等^[45]首次提出基于RNN的语义合成模型MV-RNN,学习任意长度的组合向量表示并用于名词间因果或主题信息等语义关系分类。此外,SDP-LSTM(Shortest Dependency Path with LSTM)^[46]利用实体间的最短依赖路径保留最相关信息,并使用多通道RNN对句子中的实体关系分类。Geng等^[47]使用双向树形LSTM提取基于句子依存关系树的结构特征,并使用双向顺序LSTM提取基于单词的特征,将结构特征与基于单词的特征结合以优化关系抽取性能。

3) 基于注意力机制的关系抽取。

ATT能够基于权重筛选上下文相关性强的信息,提高关系抽取的质量。目前已有多种根据不同的ATT进行关系抽取的方法。

Attention-CNN^[48]考虑文本中不同信息与实体的相关性,利用词嵌入信息,将文本段编码为语义信息,通过单词级ATT确定句子中的哪些部分对实体影响最大。Lin等^[49]针对关系抽取中掺杂错误标签,导致抽取性能低下的问题,提出基于句子级ATT的关系抽取模型,通过CNN嵌入句子的语义信息,在多个实例上建立句子级ATT,减少噪声的权重。针对如何有效选择实体,APCNNs(sentence-level Attention model based on PCNNs)^[50]提出利用知识库中的信息,基于句子级ATT,补充实体背景知识。此外,SeG(Selective Gate)^[51]使用自注意力机制(Self-Attention mechanism, SATT)获取上下文的依存关系,与选择性ATT相比,该方法即使在只有一个句子时也能稳定抽取关系。

4) 基于图卷积网络的关系抽取。

GCN可以捕捉图的全局信息,具有很好的节点表示能力。基于GCN的关系抽取针对文本依存树中各词语的依存关系编码,将关系知识编码信息引入关系抽取,挖掘句子中更深层的语义信息。

C-GCN(Contextualized GCN)^[52]针对现有依存树模型在不同结构树下计算效率低、剪枝导致忽视信息等问题,提出基于GCN和修剪依存树的关系抽取方法。AGGCNs(Attention Guided GCNs)^[53]针对如何有效选取依存树中的相关信息问题,改进现有的硬剪枝策略,将ATT和GCN结合,使用软剪枝方法自动选择依存树中的相关子结构。SGCN(Self-determined GCN)^[54]使用SATT确定加权图,并使用GCN对自定义图进行编码来完成关系抽取。

5) 基于对抗训练的关系抽取。

基于神经网络的模型通常忽略了输入数据中的噪声,导致模型效果不佳。将对抗训练AT引入关系抽取,对训练数据产生对抗噪声来优化分类算法,能够有效提升模型鲁棒性。

Wu等^[55]首次提出在关系抽取中应用AT策略,Wang等^[56]在此基础上,提出了AMNRE(Adversarial Multi-lingual Neural Relation Extraction),以AT策略保证对多种语言的句子表征,提取出语义一致的关系。冯冲等^[57]使用生成式对抗网络(Generative Adversarial Network, GAN),将带ATT的BiGRU与

AT 相融合,并引入因果关系解释语句提高因果关系抽取效果。DSGAN(Distant Supervision GAN)^[58]引入 AT 框架提升关系抽取性能。

6) 基于强化学习的关系抽取。

强化学习(RL)是一类学习、预测和决策的方法框架,通过训练策略网络选择最优实例,结合神经网络进行关系抽取。

Qin 等^[59]提出了使用深度强化学习(Deep Reinforcement Learning, DRL)策略产生假阳性指标,在没有监督信息的情况下自动识别假阳性的关系类型。Takanobu 等^[60]针对现有大部分方法将实体识别和关系抽取分开,关系抽取可能存在重叠关系,提出 HRL(Hierarchical RL),将实体识别和关系抽取分为两级 RL 策略,提升了处理重叠关系时的性能。JRE_TRL(Joint entity and Relation Extraction model with Transformer and RL agent)^[61]通过强化学习策略和奖励机制过滤噪声句子并进行关系分类。

7) 实体-关系联合抽取。

实体-关系联合抽取旨在针对实体识别和关系抽取作为两个串联子任务时存在的错误传播问题,对实体和关系进行

联合建模。能够考虑到实体与关系间的语义相关性,有效解决关系重叠问题,减少误差累积,提高知识抽取的整体效果。

最早的实体-关系联合抽取方法是 Miwa 等^[62]提出的堆叠双向树型 LSTM-RNNs 模型,在考虑实体信息的情况下进行关系抽取。本质上,该方法的实体识别和关系抽取仍然是分离的,无关的实体输入还导致了信息的冗余。对此,Zheng 等^[63]使用标注机制,将联合抽取转换为标注任务,通过计算偏重损失提升实体标签间的相关性,实现联合抽取。

进一步地,考虑实体标签间的长距离依赖关系,Zheng 等^[64]提出了一种混合模型,包括用于实体抽取的双向编码器-解码器 LSTM 模型和用于关系分类的 CNN 模型,获得单词间的长距离交互关系和标签间的长距离依赖关系。陈仁杰等^[65]提出 FETI(Fusing Entity Type Information)模型,融合头尾实体的类别信息,提升联合抽取性能。

此外,还有一些方法以元组形式进行实体-关系联合抽取。例如,Nayak 等^[66]使用编码器-解码器模型,通过关系元组表示方法联合抽取实体和关系。

综上,基于神经网络的关系抽取方法对比如表 5 所示。

表 5 基于神经网络的关系抽取方法对比

Tab. 5 Comparison of relation extraction methods based on neural network

方法类型	主要动机	核心思路
卷积神经网络 PA-TMR ^[44] 等	传统方法对特征依赖高,易导致关系检测和分类错误	使用 CNN 提取单词和句子的特征
循环神经网络 MV-RNN ^[45] 、SDP-LSTM ^[46] 等	将学习句子和长短语中的语义信息表示为组合向量	利用反馈和前馈连接处理短语和句子中序列信息
注意力机制 Attention-CNN ^[48] 、APCNNs ^[50] 等	增强与实体相关的语义信息并减少与实体无关的噪声	通过 ATT 获取实体上下文信息的依存关系
图卷积网络 C-GCN ^[52] 、AGGCNs ^[53] 等	发现句子中各词间的深层语义关系	引入句法依存树编码和关系知识嵌入编码
对抗训练 AMNRE ^[56] 、DSGAN ^[58] 等	提升关系抽取模型鲁棒性	针对训练数据产生对抗噪声,使模型正则化
强化学习 HRL ^[60] 、JRE_TRL ^[61] 等	有效进行正确的关系分类,提升模型效果	强化策略移除训练数据中的假阳性实例
实体-关系联合 LSTM-RNNs ^[62] 等	有效整合和考虑实体、关系间联系	同时抽取实体和关系信息

3.1.3 属性抽取

属性抽取是知识库构建和应用的基础,通过从不同信息源的原始数据中抽取实体的属性名和属性值,构建实体的属性列表,形成完整的实体概念,实现知识图谱对实体的全面刻画。

属性抽取方法一般可分为传统的监督、无监督和半监督属性抽取,基于神经网络的属性抽取和其他类型(如元模式、多模态等)的属性抽取。

目前大部分属性抽取是从文本数据中抽取信息。传统方法中监督学习的属性抽取一般使用 HMM 和 CRF 等抽取属性。Raju 等^[67]使用名词聚类方式,从名词类中抽取属性。Shinzato 等^[68]则提出一种无监督的属性抽取方式,自动对语料库质量进行注释,生成知识库。

基于神经网络的属性抽取一般作为序列标注任务,使用序列标注模型抽取文本中的属性值。如 Zhao 等^[69]基于 BERT 预训练模型,使用 LSTM 结合 CRF 的序列标签模型抽取文本中的属性。

基于元模式的属性抽取如 Jiang 等^[70]提出的 MetaPAD,将类型化的文本模式结构命名为元结构,可以在海量语料库中发现元模式。在属性抽取的场景中,能使用这种方法发现文本中高质量的属性描述语句,作为实体的属性值。

此外,Logan 等^[71]针对属性抽取大部分是基于文本数据的现状,提出了多模态属性抽取(Multimodal Attribute Extraction, MAE)方法及数据集,实现对多种类型数据(如图像、视频、音频等)的属性抽取。

3.2 知识融合

知识融合是融合各个层面的知识,包括融合不同知识库的同一实体、多个不同的知识图谱、多源异构的外部知识等,并确定知识图谱中的等价实例、等价类及等价属性,实现对现有知识图谱的更新。如表 6 所示,知识融合的主要任务包含实体对齐(Entity Alignment, EA)和实体消歧(Entity Disambiguation, ED)。

表 6 知识融合主要任务

Tab. 6 Main tasks of knowledge fusion

知识融合任务	目的	主要方法
实体对齐	发现语义相同的实体	基于嵌入表示的实体对齐
实体消歧	消除实体在不同文本中的不同语义	结合高质量特征或上下文相似度辅助消歧

3.2.1 实体对齐

实体对齐是知识融合阶段的主要工作,旨在发现不同知识图谱中表示相同语义的实体。一般而言,实体对齐方法可分为传统概率模型、机器学习和神经网络等类别。

传统概率模型基于属性相似性关系,将实体对齐看作概率分类模型,根据相似度评分选择对齐实体。常用的模型有 CRF、马尔可夫逻辑网络(Markov Logic Network, MLN)和隐含狄利克雷分布(Latent Dirichlet Allocation, LDA)等。

基于机器学习的实体对齐将实体对齐问题看作二分类问题,可分为监督学习和无监督学习。在监督学习实体对齐中,

使用预先人工标注部分来训练模型,对未标注数据进行分类。如决策树 (Decision Tree, DT)、支持向量机 (Support Vector Machine, SVM) 等方法通过比较特征向量进行实体对齐,或考虑实体的相似度,使相似实体聚类对齐,如 Cohen 等^[72]提出的自适应实体对齐和聚类技术。

在神经网络方法中,基于嵌入的实体对齐将不同的知识图谱表示为低维嵌入,并通过计算实体嵌入间的相似度来进行实体对齐,是目前实体对齐方法的研究重点。

Sun 等^[73]将实体对齐看作分类问题,提出基于嵌入的实体对齐 Bootstrapping 方法,将可能的实体对齐标记并迭代添加到训练数据中,保证对齐的精度。Zhang 等^[74]针对实体对齐中实体特征没有被发现或没有被统一处理的问题,提出通过统一多个实体视图来学习实体对齐嵌入的框架,并通过组合策略提升跨图谱间实体对齐的性能。

此外,Trisedya 等^[75]则是从学习不同图谱中的实体间相似性出发,提出两个知识图谱间的实体对齐框架,将实体嵌入和属性嵌入结合,学习两个图谱的统一嵌入空间,提升实体对齐性能。车超等^[76]提出基于属性信息和双向对齐的图卷积模型 (Bidirectional alignment Graph Convolutional Network with Attribution information, BiGCN-A),在实体对齐中融入属性信息,并在对齐预测阶段使用双向对齐提高准确率。

3.2.2 实体消歧

实体消歧是根据给定文本,消除不同文本中实体指称的歧义(即一词多义问题),将其映射到实际的实体上。

根据有无目标知识库划分,实体消歧主要有命名实体聚类消歧和命名实体链接消歧等方法。命名实体聚类消歧将所有的实体指称与实际的目标实体进行聚类。命名实体链接消歧则是根据文本的上下文信息,将文本中的实体指称链接到候选的实际目标实体列表中。

近年来,词嵌入 (Word Embedding, WE) 在自然语言处理领域应用广泛,可以利用分布式低维向量中的语义特征消除文本中实体指称的歧义。如 Zuheros 等^[77]使用 LSTM 对目标

实体的上下文信息编码,无需使用知识库等外部资源。Ganea 等^[78]针对文档级实体消歧,提出了一种结合实体嵌入和局部上下文注意力机制 (Local Context ATtention mechanism, LCATT) 的深度学习框架,提升消歧效率。

此外,针对传统实体消歧方法难以处理上下文信息有限或相似度较高的短文本的问题,Zhu 等^[79]提出了一种基于语义和上下文相似度的命名实体消歧方法,通过计算各个单词间的语义相似度提高实体消歧的性能。张晟旗等^[80]通过拼接消歧文本和实体知识描述文本,将短文本转换为长文本,并使用局部注意力机制 (Local ATtention, LATT) 增强实体邻近上下文的语义信息。

3.3 知识加工

知识加工是在知识抽取、知识融合的基础上,对基本的事实进行处理,形成结构化的知识体系和高质量的知识,实现对知识的统一管理。知识加工的具体步骤包括本体构建 (Ontology Construction, QC)、知识推理 (Knowledge Reasoning, KR) 和质量评估 (Quality Evaluation, QE),如表 7 所示。

表 7 知识加工主要任务

Tab. 7 Main tasks of knowledge processing

知识加工任务	目的	主要方法
本体构建	构建知识数据模型和层次体系	人工编辑、实体相似度自动计算、实体关系自动抽取等
知识推理	推断未知知识,对知识图谱进行补全	逻辑规则、嵌入表示、神经网络
质量评估	保障知识的高质量	设置奖励机制或剔除低质量样本

3.3.1 本体构建

本体构建是指在模式层构建知识的概念模板,规范化描述指定领域内的概念及概念之间的关系,其过程又包括概念提取和概念间关系提取两部分。根据构建过程的自动化程度不同,可将常用的本体构建方法分为手工构建、半自动构建以及自动构建,如表 8 所示。

表 8 本体构建方法对比

Tab. 8 Comparison of ontology construction methods

方法类型	解决思路	优点	缺点
手工构建	领域专家通过手工编辑的方式构建	能够严格控制内容,并获得高质量的本体	构建成本高、效率低
半自动构建	人工参与机器辅助的方式	效率比手工构建取得提升	仍要依赖人工,难以适应大规模本体构建
自动构建	机器自动地从各种数据源中提取概念及概念间关系	能够高效、快捷地构建本体	研究尚处于起步阶段,无法完全代替人工构建

1) 手工构建。

手工构建是指领域专家通过手工编辑的方式构建本体,使用该方法能够获得高质量的本体。目前,手动构建本体的研究集中于开发一系列可视化的建模工具。典型的可视化手工本体构建工具包括: OilEd^[81]、WebODE^[82]、OntoEdit^[83] 和 Protege^[84]等。

手工构建本体虽然能够严格控制内容,但需要人工编辑大量的数据,构建成本高、效率低、扩展性差。

2) 半自动构建。

半自动构建是指通过人工参与机器辅助的方式完成本体构建,相比传统的手工构建方法,该方法能够更快速、更全面地构建本体。例如,用户可以通过 Jena^[85]提供的开源编程环境,构建知识概念及概念间关系,实现本体的半自动构建。

半自动构建虽然在一定程度上提升了本体构建的效率,

但依赖人工提取概念和关系,难以完成大规模的本体构建。

3) 自动构建。

自动构建是指利用机器自动地从各种数据源中提取概念及概念间关系,以实现本体的构建。该方法快捷高效,并且能够处理隐含知识,已经成为目前本体构建的重要研究方向。例如, MindNet^[86]使用了自动化的方式完成本体构建。

然而,本体自动构建的研究仍处于起步阶段,尚无法完全替代人工构建,仍待进一步研究。

3.3.2 知识推理

知识推理是针对知识图谱中已有事实或关系的不完备性,挖掘或推断出未知或隐含的语义关系。一般而言,知识推理的对象可以为实体、关系和知识图谱的结构等。

如表 9 所示,知识推理主要有逻辑规则、嵌入表示和神经网络三类方法,后续章节将对这些方法进行详细的阐述。

表9 知识推理方法对比
Tab. 9 Comparison of knowledge reasoning methods

方法类别	方法类型	核心思路
基于逻辑规则	逻辑方法	直接使用一阶谓词逻辑、描述逻辑等方式对专家构建的规则进行表示及推理
	统计方法	利用机器学习方法从知识图谱中自动挖掘出隐含的逻辑规则
	图结构方法	利用图谱的路径等结构作为特征,判断实体间是否存在隐含关系
基于嵌入表示	张量分解方法	将关系张量分解为多个矩阵,利用其构造出知识图谱的一个低维嵌入表示
	距离模型	将知识图谱中的关系映射为低维嵌入空间中的几何变换,最小化变换转化的误差
	语义匹配模型	在低维向量空间匹配不同实体和关系类型的潜在语义,度量一个关系三元组的合理性
基于神经网络	卷积神经网络	将嵌入表示、文本信息等数据组织为类似图像的二维结构,提取其中的局部特征
	循环神经网络	以序列数据作为输入,沿序列演进方向以递归的方式实现链式推理
	图神经网络	以图结构组织知识,对节点的邻域信息进行学习,实现对知识拓扑结构的语义表征
	深度强化学习	将知识实体、邻接关系分别构建为状态空间和行动空间,采用实体游走进行状态转换

3.3.3 质量评估

知识图谱质量评估通常在知识抽取或融合阶段进行,对知识的置信度进行评估,保留置信度高的知识,有效保障知识图谱质量。质量评估的研究目的通常为提高知识样本的质量,提升知识抽取的效果,增强模型的有效性。

例如,Zeng等^[87]基于RL框架,通过比较深度模型的关系抽取结果和答案生成长期奖励,从而引导关系抽取的训练过程。Feng等^[88]提出基于噪声数据的句子级关系分类模型,借助强化学习思路建立实例选择器,选择高质量的句子样本,然后基于关系分类器的正确率设计奖励函数,再反馈回实例选择器,促进其选出更高质量的样本,实现了样本选择与关系分类的联合优化。

除了设置奖励和剔除低质量句子,为提高样本利用率,低质量或者错误的数据样本也可以作为训练集中的负样本进行数据增强。如Qin等^[59]利用DRL技术,完成标签质量的自动检测。不同于直接丢弃识别的错误标签样本,该模型将假阳性句子以负样本形式加入到数据集中,在提高数据质量的同时实现了数据增强,从而显著改善关系抽取效果。

3.4 知识更新

知识更新是随着时间的推移或新知识的增加,不断迭代更新知识图谱的内容,保障知识的时效性。

知识更新有模式层更新和数据层更新两种层次,包括全面更新和增量更新两种方式,如表10所示。

表10 知识更新内容
Tab. 10 Content of knowledge update

更新类别	更新类型	更新内容
更新层次	模式层更新	知识类更新,如概念、实体、关系、属性等
	数据层更新	具体知识(三元组)更新
更新方式	全面更新	将新知识与原知识全部结合,重新构建图谱
	增量更新	将新知识作为输入数据,加入现有知识图谱中

3.4.1 知识更新层次

1) 模式层更新。

当新增的知识中包含了概念、实体、关系、属性及其类型变化时,需要在模式层中更新知识图谱的数据结构,包括对实体、概念、关系、属性及其类型的增、删、改操作。一般而言,模式层更新需要人工定义规则表示复杂的约束关系。

2) 数据层更新。

数据层更新主要是指新增实体或更新现有实体的关系、属性值等信息,更新对象为具体的知识(如三元组),更新操作一般通过知识图谱构建技术自动化完成。在进行更新前,需要经过知识融合、知识加工等步骤,保证数据的可靠性和有效性。

3.4.2 知识更新方式

1) 全面更新。

全面更新指将更新知识与原有的全部知识作为输入数据,重新构建知识图谱。全面更新方法操作简单,但消耗资源多。

2) 增量更新。

增量更新只以新增的知识作为输入数据,在已有的知识图谱基础上增加知识,消耗的资源较少,但是技术实现较为困难,且需要大量的人工定义规则。

4 知识推理

知识推理在整个知识图谱理论与技术框架中占据着十分重要的地位,是知识图谱研究的一大重点和难点,在实际工程中也有非常广泛的应用场景。因此,本章将详细介绍基于逻辑规则、基于嵌入表示和基于神经网络的知识推理方法。

4.1 基于逻辑规则的知识图谱推理

基于逻辑规则的推理是指通过在知识图谱上运用简单规则及特征,推理得到新的事实,该方法能够很好地利用知识的符号性,精确性高且能为推理结果提供显式的解释。

根据推理过程中所关注的特征不同,又可将基于逻辑规则的知识图谱推理方法分为基于逻辑的推理、基于统计的推理以及基于图结构的推理。

4.1.1 基于逻辑的推理

基于逻辑的推理是指直接使用一阶谓词逻辑FOL、描述逻辑(Description Logic)等方式对专家制定的规则进行表示及推理,这类方法具有精确性高、可解释性强的特点。根据规则依托的表示方式不同,基于逻辑的推理方法又可分为基于一阶谓词逻辑的推理和基于描述逻辑的推理。

1) 基于一阶谓词逻辑的推理。

基于一阶谓词逻辑的推理是指使用一阶谓词逻辑对专家预先定义好的规则进行表示,然后以命题(Propositions)为基本单位进行推理,该方法使用接近人类自然语言的方式对知识进行表示和推理,精确性高且可解释。

其中,命题包含个体和谓词,个体对应知识图谱中的实体,谓词对应知识图谱中的关系。如图5所示,已知三元组(Bruce, HasChild, Carl)和(Bruce, IsCitizenOf, New York),则有如下的一阶谓词逻辑推理规则:

$$(Bruce, HasChild, Carl) \wedge (Bruce, IsCitizenOf, New York) \Rightarrow (Carl, IsCitizenOf, New York)$$

典型工作是Richardson等^[89]提出的马尔可夫逻辑网络(MLN),结合专家定义的逻辑规则与概率图模型构建网络,并在构建好的网络上执行推理。后续,研究者们对MLN进行了进一步的研究。例如,Pujara等^[90]为了在MLN中引入置信值,

使用概率软逻辑来执行推理,Kuželka等^[91]在理论上研究了缺少数据的情况下从知识图谱中学习MLN权重的适用性。基于一阶谓词逻辑的知识图谱推理方法简单、易理解,在小规模知识图谱上取得了较好的精度。




图5 基于逻辑规则的推理实例
Fig. 5 Example of knowledge reasoning based on logic rules

2) 基于描述逻辑的推理。

基于描述逻辑的推理关键在于将知识图谱中的复杂实体或关系推理转换为一致性检测问题,该方法有效地降低了知识图谱模型的推理复杂度,取得了表达能力和推理复杂度的平衡。具体而言,使用描述逻辑表示的知识图谱由术语集(Terminological Axioms, TBox)和断言集(Assertional Axioms, ABox)组成^[92],TBox包含描述概念和关系的一系列公理,ABox中则包含TBox中概念的实例,基于描述逻辑的推理方法通过确定一个描述是否满足逻辑一致性,实现知识图谱推理。

典型算法是Halaschek-Wiener等^[93]提出的描述逻辑推理算法,该方法通过添加和删除ABox断言补全知识图谱。在此基础上,许多学者对基于描述逻辑的知识图谱推理进行了进一步研究。例如,Calvanese等^[94]提出了基于认知的一阶查询语言EQL,用于处理推理过程知识图谱的信息不完备问题。Li等^[95]和Stoilos等^[96]通过使用模糊理论扩展了传统的描述逻辑,使推理具有模糊能力。Krötzsch等^[97]提出了属性描述逻辑,丰富了知识图谱对现实世界的建模能力。胡博等^[98]提出了一种基于描述逻辑的上下文知识获取与推理方法,用于上下文感知。此外,Bienvenu等^[99]开发了一个框架,为描述逻辑推理提供可解释性。

4.1.2 基于统计的推理

基于统计的推理关键在于利用机器学习方法,从知识图谱中自动挖掘出隐含的逻辑规则,并将这些规则用于推理。该方法摒弃了专家定义规则的模式,可利用挖掘的规则解释推理结果。基于统计的推理方法又分为基于归纳逻辑编程的推理和基于关联规则挖掘的推理。

1) 基于归纳逻辑编程的推理。

基于归纳逻辑编程(Inductive Logic Programming, ILP)的推理是指使用机器学习和逻辑编程技术,在知识图谱上自动归纳出抽象的规则集,以完成推理,该方法摒弃了人工定义规则的模式,在小规模的知识图谱上具有较好的推理能力。

典型算法是Schoenmackers等^[100]提出的一阶规则学习算法(First Order Inductive Learner, FOIL),该方法将知识图谱中关系的霍恩子句集(Horn Clauses)作为特征,采用穷举搜索算法,为每个关系建立判别器,以预测指定实体间是否存在该关系。后续出现了许多关于FOIL算法的改进算法,例如,Landwehr等^[101]通过将贝叶斯算法与FOIL算法结合在一起,扩展了FOIL算法处理不确定知识的能力,随后,他们又在FOIL算法中引入核方法^[102],降低了算法复杂度。

2) 基于关联规则挖掘的推理。

基于关联规则挖掘的推理关键在于从知识图谱中自动挖掘出高置信度的规则,并利用这些规则在知识图谱上推理以得到新的知识,相较于传统的归纳逻辑编程方法,基于关联规

则挖掘的推理可以处理更复杂、更庞大的知识图谱,且规则挖掘的速度更快。

典型算法是Galárraga等^[103]提出的基于不完备知识库的关联规则挖掘算法(Association rule Mining under Incomplete Evidence, AMIE)。AMIE算法通过在知识图谱上挖掘霍恩规则(Horn Rules),并将这些规则应用于知识图谱中得到新的事实,以补全知识图谱并检测图谱中的错误。在此基础上,Galárraga等^[104]又提出了AMIE+系统,以挖掘更大的知识图谱。Wang等^[105]提出了RDF2Rules模型,克服了AMIE和AMIE+系统一次只能挖掘一条规则的缺点。文献[106-107]分别针对AMIE规则质量的评估方式和规则挖掘的速度进行了改进。此外,李智星等^[108]提出了一种基于非结构化文本增强关联规则的知识图谱推理方法,从非结构化文本表述中抽象出文本表述模式,然后结合知识图谱已有知识构建规则。

4.1.3 基于图结构的推理

基于图结构的推理是指利用图谱的结构作为特征完成推理任务。其中,知识图谱中最为典型的结构是实体间的路径特征,对于知识图谱推理具有重要作用。基于图结构的知识图谱推理具有推理效率高且可解释的优点。例如,在图5中,从实体“Carl”出发,利用关系路径“HasWife → HasChild”能够推理出实体“Carl”和实体“Barry”可能存在“HasChild”关系。根据关注特征的粒度不同,基于图结构的推理方法又可分为基于全局结构的推理以及加入局部结构的推理。

1) 基于全局结构的推理。

基于全局结构的推理是指对整个知识图谱进行路径提取,然后将实体之间的路径作为特征用于判断实体间是否存在目标关系,该方法能够自动挖掘路径规则且具有可解释性。

典型算法为Lao等^[109]提出的路径排序算法(Path Ranking Algorithm, PRA)。该算法将知识图谱中连接目标关系实体对的路径作为特征,为每类关系训练一个逻辑回归模型,从而完成知识图谱推理任务。PRA采用的随机游走策略需要巨大的计算代价,为此,出现了Cor-PRA^[110]、CPRA^[111]、ELP(Enhance Link Prediction)^[112]等改进算法,旨在提升PRA算法路径搜索的效率及推理性能。知识图谱中的实体和关系服从长尾分布,即只有少量的实体和关系拥有较高的出现频率^[113],由此导致的数据稀疏性问题对基于全局结构的推理算法性能影响较大。

2) 引入局部结构的推理。

引入局部结构的推理是指利用与推理高度相关的局部图谱结构作为特征进行计算,以实现知识图谱的推理,相较于基于全局结构的推理,该方法的特征粒度更细且计算代价低。

典型算法包含SFE(Subgraph Feature Extraction)^[114]、HIRI(Hierarchical Random-walk Inference)^[115]等。对于目标实体,SFE算法首先使用广度优先搜索法得到局部子图,然后对其进行多特征提取,最后根据提取的特征进行推理。HIRI算法是一种分层随机游走算法,通过提取知识图谱中特定关系子图的拓扑结构,来提高基于随机游走的推理性能。此外,刘峤等^[116]提出了一种双层随机游走算法(Two-tier Random Walk Algorithm, TRWA),同时考虑特定关系的子图和关系语义的双向性。这类方法考虑更细的局部结构特征,提升了推理能力和推理效率;但由于只考虑了特定实体或关系子图的结构,忽略了子图之间的关系,具有一定的局限性。

综上,基于逻辑规则的知识图谱推理各类方法对比分析如表11所示。

表 11 基于逻辑规则的知识图谱推理方法对比

Tab. 11 Comparison of knowledge graph reasoning methods based on logic rules

类型	具体方法	核心思路	存在问题
基于逻辑的推理	基于一阶谓词逻辑的推理	使用一阶谓词逻辑表示规则，	依赖专家定义的规则；
	MLN ^[89] 、Reasoning based on PSL ^[90] 等	以命题为基本单位进行推理	计算复杂度高
	基于描述逻辑的推理	使用描述逻辑表示规则，将实体或关系推理	依赖专家定义的规则；
基于统计的推理	Description Logic Reasoning ^[93] 、EQL-Lite ^[94] 等	转换为一致性检测问题	计算复杂度高
	基于归纳逻辑编程的推理	使用机器学习和逻辑编程，在知识图谱上自	穷举搜索计算开销大
	FOIL ^[100] 、nFOIL ^[101] 等	动归纳出抽象规则集以完成推理	
基于图结构的推理	基于关联规则挖掘的推理	通过从知识图谱中自动挖掘出高置信度规	规则学习搜索空间大，效率低；
	AMIE ^[103] 、AMIE+ ^[104] 等	则，并利用这些规则完成推理	挖掘规则覆盖率低，预测效果差
	基于全局结构的推理	通过对整个知识图谱进行路径提取，将实体	路径提取效率低；
基于图结构的推理	PRA ^[108] 、Cor-PRA ^[110] 等	之间的路径作为特征以完成推理	难以处理关系稀疏的数据
	引入局部结构的推理	利用与推理高度相关的局部图谱结构作为特	忽略局部子图间关系，
	SFE ^[114] 、HIRI ^[115] 等	征进行计算，实现知识图谱推理	挖掘的路径规则覆盖率低

4.2 基于嵌入表示的知识图谱推理

在机器学习中，嵌入表示是一种非常重要的技术手段，通过嵌入表示可以将复杂的数据结构转化为向量化的表示，为后续工作的开展提供便利。对于知识图谱推理，嵌入表示的技术优势同样明显。通过将图结构中隐含的关联信息映射到欧氏空间，使得原本难以发现的关联关系变得显而易见。因此，基于嵌入表示的推理是知识图谱推理技术的重要组成部分。

接下来介绍三类嵌入推理的方法，分别是张量分解方法、距离模型和语义匹配模型。

4.2.1 张量分解方法

张量分解 (Tensor Decomposition, TD) 方法是通过特定技术将关系张量分解为多个矩阵，利用这些矩阵可以构造出知识图谱的一个低维嵌入表示。通过对基本张量分解算法进行改进和调整，并加以应用，这类模型能够快速训练出一个知识图谱的嵌入表示。

当前用于嵌入推理的张量分解方法以 RESCAL^[117-118] 为主。该模型将知识图谱中的知识以一个三阶张量的形式表示，该张量反映了知识图谱中实体-关系-实体的三元组结构。RESCAL 通过对张量进行分解，得到实体和关系类型的嵌入表示，该嵌入表示反映的是实体或关系邻域结构的相似性。如图 6 所示，“Carl”和“Arthur”均是一个学生的导师，均教授一门课程，也都主持了一个项目。由于两人邻域结构高度相似，RESCAL 模型得到的两人的嵌入表示也是相近的，由此可推理出二人存在关联关系，结合背景知识，这一关系很可能是“ColleagueOf”。




图 6 嵌入表示知识推理实例

Fig. 6 Example of knowledge reasoning based on embedding representation

RESCAL 是一个十分经典的张量分解模型，但由于其分解原理简单，考虑因素相对单一，不适应于部分复杂的应用场景。因此，部分研究以此为基础，提出了改进的模型。YAGO^[119] 在 RESCAL 的基础上添加了用于处理实体属性信息的模块，是 RESCAL 模型的一个扩展。Rendle 等^[120] 考虑了知识图谱中的二元组关系，即主体-关系类型关系、主体-客体关系、关系类型-客体关系。Rendle 等^[121] 进一步提出在线性时间内学习大规模的关系型数据，该方法在知识图谱的链路预测和推荐系统方面有重要价值。Jenatton 等^[122] 提出了通过概率模型学习稀疏的关系表示，以此处理关系数量极大的知识图谱嵌入表示问题。

4.2.2 距离模型

距离模型 (Distance Model, DM) 又可分为平移模型 (Translational Model, TM)，该类模型将知识图谱中的每个关系看作从主体向量到客体向量的一个平移变换。通过最小化平移转化的误差，将知识图谱中的实体和关系类型映射到低维空间。

典型的距离模型是 TransE^[123]，该模型将知识图谱中的实体和关系类型都嵌入为低维的向量。将知识图谱中的每个关系理解为从主体向量到客体向量的一个平移变换，即该模型要求主体向量、关系类型向量和客体向量满足 $h + r \approx t$ 。

如图 7 所示，TransE 通过学习已有知识，将四个人物实体映射为低维空间的四个点 (即点 A、B、C、D)，同时将“Thomas”和“Pamela”二人之间已知的“ColleagueOf”关系映射为向量 α (即向量 \overrightarrow{CD})。在推理“Carl”和“Arthur”是否存在同事关系时，只需判断“ColleagueOf”这一关系的嵌入向量 α 能否在低维空间中近似地实现从“Carl”的嵌入点 (A 点) 到“Arthur”的嵌入点 (B 点) 的平移。如果能，则可推出 (Carl, ColleagueOf, Arthur) 这一关系存在；反之则认为该关系不存在。




图 7 TransE 实体和关系映射实例

Fig. 7 Example of entity and relation mapping of TransE

TransE模型通过上述这种直观的映射方式,使得知识推理在实际应用中有很好的可解释性。然而,TransE模型的性能受到两个方面的制约:一方面是其平移转化这一要求过于严格,导致灵活性和鲁棒性受到影响;另一方面则是该模型无法处理知识图谱中的非一对一的关系,对学习效果造成了一定影响。针对这两个问题,研究者们对TransE做出了改进。

针对第一个问题,一些松弛化模型被提出。TransM^[124]模型给每种关系类型定义了一个权重,以衡量该关系类型在优化目标中的重要性。ManifoldE^[125]将平移转化约束做了进一步松弛,提出了一种基于流形的知识图谱嵌入模型,要求平移后的向量落在相应的流形之上。TransF^[126]则是以一种线性的方式对平移转化约束做出松弛化处理,增强了模型处理复杂的带噪声数据的能力。TransAt^[127]在模型中引入了注意力机制,更加关注与特定关系相关的属性,忽略无关属性的干扰,使得算法更具鲁棒性。TransA^[128]是一种基于马氏距离的更灵活的知识图谱嵌入模型。

针对第二个问题,主要思路是将实体和关系在特定投影空间进行平移转化。为了更好地处理非一对一的关系,并且一定程度上保留TransE的效率和简洁性,TransH^[129]将关系类型拟合为一个超平面。TransR^[130]受此启发,引入了实体空间和关系空间的概念,将实体和关系类型在各自的空间中分别建模。TransR模型是对TransE的一个非常经典的改进,但存在的主要问题是运算开销过高。一些研究尝试在保留TransR性能的同时,降低其模型复杂度。TransD^[131]中每一个实体或关系都被表示为两个向量,这大大减少了参数的数量,同时避免了大量矩阵乘法,降低了运算开销。TransSparse^[132]也是对投影矩阵的一个简化,利用稀疏矩阵显著降低了模型的参数数量,降低了训练的复杂度。TransAH^[133]采用了一种自适应的度量方法,加入了对角权重矩阵将得分函数中的度量由欧氏距离转换为加权欧氏距离,并实现了为每一个特征维区别地赋予权重,引入面向特定关系的超平面模型,将头实体和尾实体映射至给定关系的超平面加以区分。

除了上述两类改进模型以外,研究者还提出了对于TransE的一些其他改进思路。KG2E^[134]是一种基于密度的知识图谱嵌入表示学习方法,在多维高斯分布空间中学习知识图谱的嵌入表示。TransG^[135]将实体和关系类型表示为服从高斯分布的随机向量,认为同一个关系在不同的首尾实体的背景下可能有多个语义。Rotate^[136]引入了复空间,将实体和关系类型的嵌入表示构建在复空间中,将关系看作是头实体经过旋转变换得到尾实体,而非平移变换,这一观念的转变是极具启发性的。TorusE^[137]则将嵌入的空间从向量空间迁移到一个环面(Torus)上,将这个环面作为知识图谱的嵌入空间。CEKGRL(Category-Enhanced Knowledge Graph Representation Learning)^[138]模型在TransE模型的基础上引入实体的类别表示,旨在学习三元组知识的同时,能够通过类别信息得到更加准确的知识表示。彭敏等^[139]在TransE的基础上提出了聚合邻域信息的联合知识表示模型TransE-NA(Neighborhood Aggregation on TransE),缓解数据稀疏问题,改善知识表示性能。MCKRL(Knowledge Representation Learning based on Multi-source information Combination)^[140]引入卷积神经网络和图注意力机制,构建了基于TransE的编码器-解码器模型,对知识图谱中的三元组信息、文本描述信息、实体层次类型信息和图结构信息进行融合,实现基于多源信

息组合的知识表示学习。

4.2.3 语义匹配模型

语义匹配模型(Semantic Matching Models)通过设计基于相似度的目标函数,在低维向量空间匹配不同实体和关系类型的潜在语义,定义基于相似性的评分函数,度量一个关系三元组的合理性。该类模型认为训练集中存在的关系三元组应该有较高的相似度,而训练集中没有的关系应该有相对较低的相似度。

常用的语义匹配模型,如TATEC(Two And Three-way Embeddings Combination)^[141]模型,主要思路是对知识图谱中的二元语义和三元语义进行匹配,衡量各关系的合理性。在匹配主体-关系类型-客体的三元语义的同时,也对主体与关系类型、关系类型与客体和主体与客体等三类语义进行匹配,使得模型有更强的拟合能力和灵活性。

例如,针对图6中的关系网络,TATEC模型首先定义一个语义评分函数,用于衡量三元和二元语义关系的合理性。如对于三元组(Carl, Teaches, OperatingSystem),其对应的三元语义的评分为0.35,二元语义(Carl, Teaches)、(Teaches, OperatingSystem)和(Carl, OperatingSystem)的评分分别为0.25、0.13和0.18。将上述四个分数求和,即得到关系三元组(Carl, Teaches, OperatingSystem)的语义评分为0.91。训练时要求所有已知关系三元组的语义评分尽可能高。在推理“Carl”和“Arthur”是否为同事关系时,根据训练得到的实体和关系的嵌入表示,计算得(Carl, ColleagueOf, Arthur)这一三元组的语义评分为0.85,该评分高于预设的经验性阈值0.75,因此可判断该关系成立。

TATEC模型的运算复杂度较高,因为其空间映射矩阵中待训练参数数量较大,改进模型尝试平衡TATEC的效果和复杂度。DistMult^[142]要求模型中的空间映射矩阵是一个对角矩阵,以此大大减少模型的参数数量,使得模型的训练难度降低,但也导致其效果相比TATEC略弱。张金斗^[143]提出在DistMult的基础上引入偏序关系建模层次结构的方法,实现了结合层次类别信息知识图谱表示学习。HoIE^[144]引入了向量卷积,实现了主客体的信息融合,基于DistMult,一定程度上增加了复杂度,却大幅提升了模型拟合能力。Complex^[145]在DistMult模型的基础上引入了复空间,将实体和关系类型映射到低维复数空间。QuatE^[146]在Complex的复向量表示基础上,提出了超复空间(Super-Complex Space)的向量表示,并将实体和关系映射到该空间。ANALOGY^[147]模型在TATEC基础上,进一步考虑了实体的隐喻关系。

为了提高对非线性模式的捕捉能力,一系列基于神经网络的模型被提出。SME(Semantic Matching Energy)^[148]模型是基于神经网络学习关系和实体低维向量表示的模型。该模型首先将实体和关系输入到神经网络的输入层,并将其映射为向量,通过学习两个带参数的函数,可以得到关系和实体的低维向量表示形式。NTN(Neural Tensor Networks)^[149]加入了非线性函数,增强了拟合能力,但是其所需训练的参数数量较大,因而训练所需的开销大幅增加了。Dong等^[150]使用一个简单的多层感知机的方法,实现了主体-关系类型-客体的三部分信息融合。NAM(Neural Association Models)^[151]采用了深度神经网络方法,提升了模型的拟合能力。

综上,基于嵌入表示的知识推理方法对比如表12所示。

表 12 基于嵌入表示的知识图谱推理方法对比

Tab. 12 Comparison of knowledge graph reasoning methods based on embedding representation

具体类型	具体方法	核心思路	存在问题
张量分解方法	RESCAL ^[117-118] 及其改进	利用已有张量分解算法,分解三阶关系张量,高效计算嵌入表示	方法较为简单,效果有限,可解释性较弱
距离模型	简单平移模型	将关系解释为向量空间平移变换,对嵌入表示进行优化计算	平移转化要求严格,难以对抗噪声,且无法处理非一对一关系
	松弛化平移模型	对简单平移模型加以松弛化处理,允许平移转化一定的偏差	松弛化程度难以把控,导致模型有效性降低
	ManifoldE ^[125] 、TransF ^[126] 等		
	投影空间平移模型	分离实体空间和关系空间,在投影空间进行平移转化的计算	跨空间投影运算开销较高,参数数量较多,模型训练难度大
语义匹配模型	TransH ^[129] 、TransR ^[130] 等		
	线性语义匹配	进行二元和三元的语义匹配,构建线性优化目标	线性模型结构难以捕捉非线性语义关系
	TATEC ^[141] 、DistMult ^[142] 等		
	神经网络的语义匹配	利用深度神经网络,实现对非线性语义关系的学习	神经网络模型训练开销高,可解释性不足
	SME ^[148] 、NTN ^[149] 等		

4.3 基于神经网络的知识图谱推理

基于神经网络的知识图谱推理,充分利用了神经网络对非线性复杂关系的建模能力,能够深入学习图谱结构特征和语义特征,实现对图谱缺失关系的有效预测。

一般地,应用于知识图谱推理的神经网络方法主要包括 CNN 方法、RNN 方法、图神经网络(Graph Neural Network, GNN)方法、DRL 方法等,相关方法的基本流程如表 13 所示。

表 13 基于神经网络的知识图谱推理方法基本流程

Tab. 13 Basic processes of knowledge graph reasoning methods based on neural network

具体类型	输入	推理核心方法	输出
CNN 方法	实体文本描述或实体关系交互	卷积操作	文本嵌入或交互特征
RNN 方法	知识路径结构或实体文本描述	循环结构	路径嵌入或文本嵌入
GNN 方法	知识图谱拓扑结构	GCN、GAT	实体关系嵌入
DRL 方法	知识图谱拓扑结构	路径生成策略	路径嵌入和路径生成策略

4.3.1 卷积神经网络方法

基于 CNN 的知识图谱推理方法,通过卷积操作提取知识局部特征,预测图谱中的缺失关系。主要包括基于实体文本描述(Entity Text Description, ETD)的推理和基于实体关系交互的推理两大类。

1) 基于实体文本描述的推理。

ETD 是对知识图谱中实体语义信息的详细描述。基于 ETD 的 CNN 推理,指利用 CNN 对 ETD 进行解析,从中提取出关键的文本片段并转换为嵌入向量,进而利用文本特征辅助对实体语义的准确理解。

其中,典型方法包括 DKRL、ConMask、TECRL 等模型。具体而言,Xie 等^[152]提出 DKRL(Description-embodied Knowledge Representation Learning)模型,针对知识图谱中的实体描述信息,利用连续词袋模型(Continuous Bag-of-Words, CBOW)和 CNN,分别学习文本描述中的无序特征和词序特征,并融合生成最终的知识嵌入表示进行推理,实现新实体的有效发现。进一步地,Shi 等^[153]提出 ConMask(Content Masking)模型,利用 CNN 融合了文本描述特征与实体语义信息。鲍开放等^[154]针对文本描述的编码结果,结合翻译模型对实体关系进行联合学习,实现复杂关系语义的有效表达。Zhao 等^[155]提出 TECRL(Text-Enhanced Convolutional Representation Learning)模型,对文本描述先后使用两次卷积操作提取特征。

2) 基于实体关系交互的推理。

实体关系交互指在同一个三元组中,实体语义和关系语义的相互关系,其反映了知识结构的语义。基于实体关系交互的 CNN 推理,指利用 CNN 对实体关系嵌入向量拼接而成的二维矩阵执行卷积操作,从中提取出实体、关系语义的交互信息,进而提升对知识三元组结构语义的理解。

其中,典型方法包括 ConvE、InteractE、M-DCN、

Convolution-based KG 等模型。具体而言,Dettmers 等^[156]提出 ConvE 模型,针对实体关系嵌入向量构成的二维矩阵,利用二维卷积、嵌入投影、内积等简单运算,实现实体关系间交互特征的有效捕捉。进一步地,Vashishth 等^[157]提出 InteractE 模型,利用特征置换、方形特征重塑、圆形卷积等技术,进一步增加实体关系间交互数量。Zhang 等^[158]提出 M-DCN(Multi-scale Dynamic Convolutional Network)模型,交替输入实体关系嵌入,有效学习知识间交互的序列特征。李少杰等^[159]提出 ConvKE 模型,利用维度变换策略提升卷积滑动窗口的滑动步数,增强了知识间交互信息的学习能力。Annervaz 等^[160]提出 Convolution-based KG 模型,结合注意力机制,实现对实体关系聚集结构的深入分析。

4.3.2 循环神经网络方法

基于 RNN 的知识图谱推理方法,指基于循环结构提取知识序列特征,预测图谱中的缺失关系,主要包括基于知识路径语义的推理和基于 ETD 的推理两大类。

1) 基于知识路径语义的推理。

知识路径指知识图谱中由实体关系交替组成的有序路径,其中蕴含了从起点实体到终点实体间的隐藏语义。基于知识路径语义的 RNN 推理,指利用 RNN 结构特征,迭代学习路径的语义特征,从中发现关联路径上的隐含语义信息,并基于此实现缺失知识的准确预测。

其中,典型方法包括 RNN+PRA Classifier、Single-Model、DSKG 等模型。具体而言,Neelakantan 等^[161]提出 RNN+PRA Classifier 模型,通过迭代使用 RNN,有效学习知识路径的组合表示,并在路径嵌入空间上实现知识推理。进一步地,Das 等^[162]提出 Single-Model 模型,通过引入神经注意力(Neural Attention, NATT)机制,有效组合多条关系路径的语义信息。Jagvaral 等^[163]则同时建模了路径的双向语义。Guo 等^[164]提出

DSKG (Deep Sequential model for KG)模型,采用两个独立的RNN单元对实体关系分别进行建模。

2) 基于实体文本描述的推理。

除CNN外,对于蕴含详细语义信息的ETD而言,也可以利用RNN进行分析建模。一般地,基于ETD的RNN推理,利用RNN依次读入ETD信息,完成不同三元组中实体语义信息的匹配,从而实现对缺失知识的准确预测。

其中,典型方法包括KGD L等模型。具体而言,Chen等^[165]提出KGD L (learning Knowledge Graph embedding with entity Descriptions based on LSTM networks)模型,采用LSTM逐词编码相关文本描述,再嵌入三元组编码的实体描述,实现对缺失知识的预测。进一步地,Zhao等^[166]结合完全注意力(Complete ATTention, CATT)机制编码实体描述,学习到了实体在不同三元组中的具体语义。靳京^[167]提出T-CRNN模型,先利用CNN提取实体描述中的单词特征,再利用门控循环网络(Gate Recurrent Unit, GRU)学习实体描述的上下文信息,实现实体描述语义信息的深入挖掘。An等^[168]结合互注意力(Mutual ATTention, MATT)机制整合多种文本语料信息,从而捕捉到实体关系在不同三元组中的语义变化。

4.3.3 图神经网络方法

基于GNN的知识图谱推理方法,指基于GNN提取出图谱拓扑结构特征,预测图谱中的缺失关系,主要包括基于GCN的推理与基于图注意力网络的推理两大类。

1) 基于GCN的推理。

GCN^[169]引入傅里叶变换,将图结构信息变换到由图拉普拉斯矩阵特征向量构成的正交空间中,从而实现邻域向中心的信息聚合。同理,基于GCN的推理,将图谱视作无向图,利用GCN分析拓扑结构,实现邻域向中心实体的语义汇聚。

其中,典型方法包括SACN、R-GCN、RGHAT等模型。具体而言,Shang等^[170]提出SACN (Structure-Aware Convolutional Network)模型,将一个加权GCN作为编码器,卷积网络ConvTransE作为解码器,自适应地学习节点邻域结构的语义信息。进一步地,Schlichtkrull等^[171]提出R-GCN (Relational Graph Convolutional Network)模型,在消息传递过程中引入了特定于关系类型的转换矩阵,能够学习多种类型的关系语义。聂斌玲^[172]提出SAGCN (Structure Aware Graph Convolutional Network)模型,综合了实体相邻节点与相邻边的语义信息,实现实体语义的完整表达。Zhang等^[173]提出RGHAT (Relational Graph neural network with Hierarchical ATTention)模型,结合层次注意力(Hierarchical ATTention, HATT)机制,能够更加有效地利用实体邻域信息。

2) 基于GAT的推理。

GAT (Graph Attention Networks)^[174]是一种基于空间结构的图神经网络,在聚合邻域特征信息时,通过ATT确定邻居节

点权重信息,从而实现邻域对中心贡献程度的自适应调节。同理,基于GAT的推理,将图谱视作有向图,利用GAT分析拓扑结构,实现邻域结构对中心实体语义贡献的准确量化。

其中,典型方法包括DPMPN、ExpressGNN-E、ReInceptionE等模型。具体而言,Xu等^[175]提出DPMPN (Dynamically Pruned Message Passing Networks)模型,同时编码通用的全图表示和针对输入信息的局部表示,实现推理过程中子图的动态构建。进一步地,Zhang等^[176]提出ExpressGNN-E模型,组合了MLN和GNN,能够进行有效的概率逻辑推理。Xie等^[177]提出ReInceptionE模型,结合ConvE和KBGAT^[178],利用关系感知注意力(Relation-Aware ATTention, RAATT)机制实现对图谱结构信息的深入理解。康世泽等^[179]提出HE-GAN-NC (HE-GAN toward Node Classification)模型,通过堆叠图注意力网络,有效学习实体的高阶邻居特征,实现对知识图谱语义的完整表达。

4.3.4 深度强化学习方法

基于DRL的知识图谱推理方法,结合了深度学习对图谱结构的感知能力与强化学习对补全关系的决策能力,将图谱上的推理建模为序列决策模型。该类方法主要指基于关系路径探索的推理。

基于关系路径探索的推理将知识实体、邻接关系分别构建为状态空间和行动空间,采用实体游走进行状态转换,发现正确答案即生成奖励。从而基于“关系-路径-探索”建立推理方案,能够显著提升知识推理的有效性和多样性。

其中,典型方法包括DeepPath、MINERVA、ADRL、DAPath、MARLPar、RLH、GRL等模型。具体而言,Xiong等^[180]建立DeepPath模型,将行为定义为选择当前节点连接的某条边,基于行为序列扩展实现路径探索,并在预测出正确实体时给予奖励。进一步地,Das等^[181]提出MINERVA (Meandering In Networks of Entities to Reach Verisimilar Answers)模型,通过在查询实体邻域内进行高效搜索,能够解决答案未知的复杂推理问题。Wang等^[182]提出ADRL (Attention-based Deep Reinforcement Learning)模型,结合LSTM和ATT,使得生成轨迹具有更强的可解释性。Tiwari等^[183]提出DAPath (Distance-Aware Path)模型,结合图自注意力(Graph Self-Attention, GSA)机制和GRU的记忆机制,能够捕捉到路径邻域内更完整的实体信息。Li等^[184]提出MARLPar (Multi-Agent and Reinforcement Learning based method for Path Reasoning)模型,交替选择实体和关系,实现联合实体关系语义的知识推理。Wan等^[185]提出RLH (Reasoning Like Human)模型,先后编码历史信息和行动空间,能够有效处理多语义问题。Wang等^[186]提出GRL (GAN-based Reinforcement Learning)模型,利用GAN和LSTM生成轨迹,能够结合领域规则实现知识推理。

综上,基于神经网络的知识推理方法对比如表14所示。

表14 基于神经网络的知识图谱推理方法对比

Tab. 14 Comparison of knowledge graph reasoning methods based on neural network

具体类型	具体方法	核心思路	存在问题
CNN方法	基于实体文本描述的推理DKRL ^[152] 、ConMask ^[153] 等	对实体文本描述执行卷积操作	只能关注文本语义局部特征
	基于实体关系交互的推理ConvE ^[156] 、InteractE ^[157] 等	对知识三元组嵌入执行卷积操作	忽略了三元组间的语义关联
RNN方法	基于知识路径语义的推理Single-Model ^[162] 、DSKG ^[164] 等	迭代分析知识图谱关系路径	记忆遗忘、忽略路径之间的语义关联
	基于实体文本描述的推理KGD L ^[165] 、T-CRNN ^[167] 等	迭代分析实体文本描述	严重依赖文本的数量及质量
GNN方法	基于GCN的推理SACN ^[170] 、R-GCN ^[171] 等	基于无向边实现邻域到中心的汇聚	简单地把单向关系建模为双向关系,建模方向存在误差
	基于GAT的推理DPMPN ^[175] 、ReInceptionE ^[177] 等	基于有向边实现邻域到中心的汇聚	考虑更多跳数的邻域时存在过平滑问题
DRL方法	基于关系路径探索的推理DeepPath ^[180] 、MINERVA ^[181] 等	基于知识图谱实体关系拓扑结构构建强化学习环境	稀疏奖励、难以适应动态增长的图谱

5 超图理论与方法

尽管知识图谱被广泛采用,但基于三元组的表示方法往往过分简化了存储在知识图谱中的数据复杂性;特别是对于连接两个及以上实体的超关系数据,其中的高阶结构信息的丢失,会导致知识超图表示及推理能力受限。相关工作证明,在知识图谱 Freebase 中,超过 33.3%^[187]的实体和 61%^[188]

的关系是无法以二元关系表示的。

知识超图是一种特殊的异构图。为了更清楚地了解知识超图特点,本章首先研究异构超图表示方法。根据其知识与知识超图的关联性,进一步研究知识超图表示方法。最后提出了知识超图的三层架构,能有效提升知识超图推理能力及效率。

超图及相关图定义、特点以及其主要的任务如表 15 和图 8 所示。其中,|TV|表示节点类型数,|TE|表示关系类型数。

表 15 超图及相关图定义

Tab. 15 Definitions of hypergraphs and related graphs

图分类	图形	定义	特点	任务
同构图	图 8(a)	$H = (V, E)$, 其中 V 表示节点集合, E 表示关系集合	$ TV = 1, TE = 1$, 其节点和关系类型单一, 只能表示二元关系数据	链接预测、节点分类、聚类
异构图	图 8(b)	$H = (V, E)$, 其中 V 表示节点集合, E 表示关系集合	$ TV + TE > 2$, 其存在不止一种节点与关系, 只能表示二元关系数据	链接预测、节点分类、聚类
异构超图	图 8(c)	$H = (V, E)$, 其中 V 表示节点集合, E 表示关系集合。对于任意超边 $e \in E, e(v_1, v_2, \dots, v_n) \subseteq V$	$ TV > 1$, 其节点类型多样, 能表示超关系数据, 关系通常没有语义	链接预测、节点分类、聚类
知识超图	图 8(d)	$H = (V, E)$, 其中 V 表示实体集合, E 表示超关系集合。基本单位是超关系事实 $fact = (e, v_1, v_2, \dots, v_n)$	$ TV > 1, TE > 1$, 其实体和关系类型多样, 能表示超关系数据, 关系语义丰富	链接预测、超关系事实判断

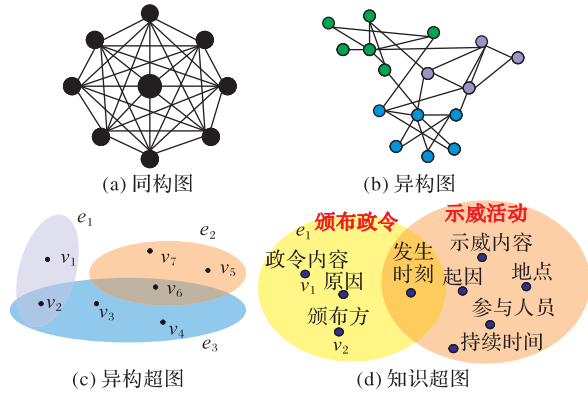


图 8 超图及相关图

Fig. 8 Hypergraphs and related graphs

5.1 异构超图表示

异构图表示为节点和边的集合,广泛存在于真实世界的众多场景中。例如表示人与人之间关系的社交网络^[189-191],作者和论文间的引用网络^[192]等。

超图以图论和集合论为基础,在聚类、空间数据挖掘等方面取得了广泛应用^[193]。超图表示为 $H = (V, E)$, V 是节点集, E 是边集,每条边包含两个或者更多节点。通常用 $|V| \times |E|$ 维关联矩阵 H 来描述超图的结构。其中, $|V|$ 表示超图中节点的数

目,称为超图的阶数, $|E|$ 表示超图中超边的数目。根据计算规则 $h(v, e)$, 如果节点 $v \in e$, 则 $h(v, e) = 1$; 否则, 如果 $v \notin e$, 则 $h(v, e) = 0$ 。




图 9 超图及其对应的邻接矩阵示例

Fig. 9 Example of hypergraph and the corresponding adjacency matrix

对于每一个超边 e 属于 E , 度矩阵 $\delta(v)$ 是超边上的顶点数目之和, 可表示为 $\delta(v) = \sum_{e \in E} h(v, e)$ 。

异构超图表示学习对于超图构建、推理以及应用均有重要意义,因此本节主要研究异构超图表示方法。异构超图表示学习旨在将节点映射为向量的同时,保留图的拓扑结构、节点与节点之间的关系以及子图等信息^[194]。

异构超图表示包括基于无监督聚类、基于随机游走、基于矩阵分解、基于神经网络和基于元路径等方法。异构超图表示的主要模型如图 10 所示。

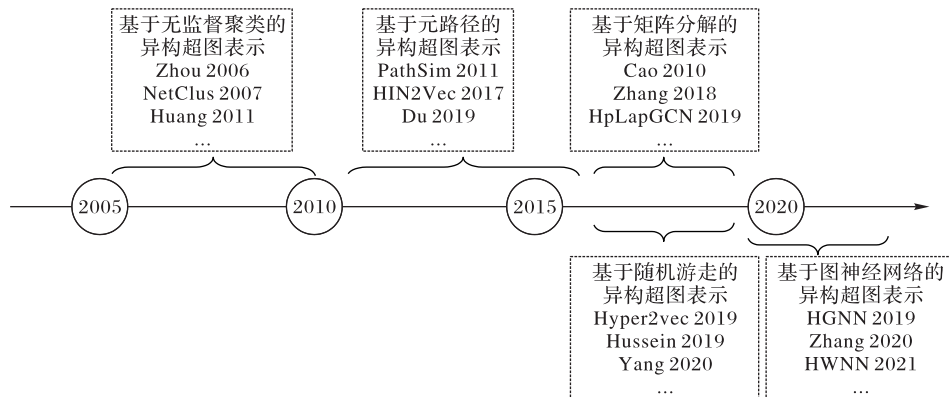


图 10 异构超图表示的主要模型

Fig. 10 Main models of heterogeneous hypergraph representation

1) 基于无监督聚类的异构超图表示学习。

基于无监督聚类的方法将相似的节点聚集在一起,使得同组的节点彼此接近,不同组的节点尽量区分开。在无可用类别标签的场景下,基于无监督的聚类能实现节点的有效划分,是学习异构图嵌入的有效方式。

Zhou等^[195]采用超图表示对象之间的复杂信息,首次将处理无向图的强大的谱聚类方法推广到超图上,并在超图聚类算法基础上提出超图嵌入算法。虽然谱聚类是超图聚类最有效的算法之一,但是传统谱聚类算法性能较差,时间与空间成本大。为此,文献[196-198]中提出了提升聚类性能的基于排名的聚类NetClus(Net Cluster)、以及解决聚类中计算成本大的GraphLSHC(Large Scale Hypergraph Clustering)^[199]等。

2) 基于元路径的异构超图表示学习。

基于元路径的方法将节点之间的一系列关系表示为一条路径,学习不同类型的节点语义信息。该方法通过度量节点之间的关联性,学习异构超图中丰富的语义信息。

PathSim(Meta Path-based Similarity Measure)^[200]是最早提出的使用元路径的异构图表示学习模型,通过基于元路径的相似度度量学习节点的表示;但是,该模型过于依赖人为定义的元路径及其权重。为此,HIN2Vec(Heterogeneous Information Network to Vector)^[201]利用了节点之间不同类型的关系,文献[202-203]中提出主动权重学习等方法。

3) 基于随机游走的异构超图表示学习。

基于随机游走的图表示学习以深度搜索的方式学习起始节点的序列信息,并使用该信息表示节点^[194]。基于随机游走的方法可以保留节点对之间的接近度,学习节点的局部结构信息。

Hyper2vec(Hyper-network to vector)^[204]首次在超图上运用有偏二阶随机游走框架,在超图表示学习中取得了良好的性能,并减少了计算时间。但是,该方法以无监督的方式生成节点嵌入,不能将节点嵌入映射到超边中,导致无法捕获超边的高阶结构信息。为此,文献[205-206]中采用随机游走,联合学习实体对关系和超关系,捕获超图高阶结构信息。

4) 基于矩阵分解的异构超图表示学习。

基于矩阵分解的方法将异构超图表示为矩阵,通过对矩阵进行分解学习节点的嵌入表示^[207-208]。基于矩阵分解的方法可以解决图的稀疏性问题,获得可扩展的图嵌入表示。基于矩阵分解的方法包括分解图的拉普拉斯特征映射和分解节点邻接矩阵。

Chung^[209]首次提出超图的拉普拉斯矩阵,在此基础上,Rodriguez^[210]研究了超图中的拉普拉斯特征值以及超图分解问题。但是,传统的方法都着重于理论的研究,难以应用到大规模超图中。为此,HpLapGCN(Hypergraph p -Laplacian Graph Convolutional Networks)^[211]利用超图的拉普拉斯矩阵,保留图的局部几何形状,结合GCN学习多种数据特征。

Cao等^[212]为了解决超图表示中的数据稀疏问题,使用非线性矩阵分解方法实现超图的表示;但由于超边大小是可变的,传统方法难以实现异构超图表示。为此,Zhang等^[213]提出了协调矩阵最小化算法,在超图上的顶点邻接域中,交替执行非负矩阵分解和最小二乘匹配,实现高性能的超图表示。

5) 基于神经网络的异构超图表示学习。

基于神经网络的方法学习异构图的结构以及节点信息等非线性关系;特别是基于GNN的模型,能够在学习节点特征的同时,捕获异构图的拓扑结构信息。

HGNN(HyperGraph Neural Network)^[214]为基于超边卷积计算的GNN模型,学习现实数据的高阶相关性。在此基础上,DHGNN(Dynamic HyperGraph Neural Network)^[215]为动态GNN模型,通过GNN提取特征来挖掘新关系,让图网络自我进化,实现动态超图构建。为了进一步提升性能,Zhang等^[216]使用了GAT模型学习可变超边大小的同构图和异构图。HWNN(Hypergraph Wavelet Neural Network)^[217]、HyperGCN(HyperGraph Convolutional Network)^[218]等模型使用了GCN模型对复杂关系进行建模。

当前,异构超图领域还有许多亟待解决的难题,相关方法思路及存在的问题如表16所示。

表16 异构超图表示方法对比

Tab. 16 Comparison of heterogeneous hypergraph representation methods

具体方法	核心思路	存在问题
基于无监督聚类 Zhou等 ^[195] 、NetClus ^[196] 等	通过谱聚类等方法对无标签超图节点进行有效划分	计算复杂度高
基于元路径 PathSim ^[200] 、HIN2Vec ^[201] 等	通过将节点之间的一系列关系表示为路径,学习节点之间不同语义关系	依赖专家经验定义元路径,难以选择最优元路径
基于随机游走 Hyper2vec ^[204] 、Huang等 ^[205]	通过深度搜索的方式学习节点序列信息,保留节点对之间的接近度	难以学习复杂的图结构,时间复杂度高
基于矩阵分解 Chung ^[209] 、Rodriguez ^[210] 等	通过分解矩阵,解决图的稀疏性问题,获得可伸缩的图嵌入	邻接矩阵表示受限,时间和空间复杂度高
基于神经网络 HGNN ^[214] 、DHGNN ^[215] 等	通过捕获图结构信息,增强表示学习能力	计算复杂度高

5.2 知识超图表示

知识超图表示学习是将超边以及实体表示为低维稠密向量空间中的向量。异构图表示学习与知识图谱表示学习两个任务都是受到word2vec(word to vector)^[219]启发提出的;但是,知识图谱中的表示学习更偏向关系建模,异构图表示学习侧重于学习图的结构信息。

知识超图表示学习包括基于软规则、基于翻译、基于张量分解以及基于神经网络等方法。知识超图表示的主要模型如

图11所示。

1) 基于软规则的知识超图表示。

基于软规则的方法将关系作为谓词,节点作为变量,通过设置关系推理的逻辑和约束条件进行简单推理。该方法可以很容易地处理可变的超关系(超边大小可变),并且具有可解释性。

MLN首次将一阶逻辑和概率图模型相结合,是一个带权重的一阶知识库。但是,该模型将概率添加到逻辑公式中,假

设性太强。ProbLog (Probabilistic Prolog)^[220] 通过将 SLD 分辨率与布尔模型结合在一起, RLR (Relational Logistic Regression)^[221] 通过将逻辑回归扩展到关系模型中改进了 MLN 模型。

2) 基于翻译的知识超图表示。

基于翻译的方法旨在将关系建模为在超关系事实中, 实体之间的某种转换操作。该方法可以处理可变的超关系数据, 并且操作较简单。

M-TransH (Multi-fold TransH)^[187] 将 TransH 扩展到超关系数据中, 是第一个基于翻译的知识超图表示模型。M-TransH 将实体映射到相关的超平面, 用映射结果的加权和定义评分函数。RAE (Relatedness Affiliated Embedding)^[222] 进一步改进了关联性假设。

3) 基于张量分解的知识超图表示。

基于张量分解的方法将超关系事实表示为 n 阶张量, 通过张量的分解学习节点的嵌入。该方法大多使用规范多元分解 (Canonical Polyadic Decomposition, CPD), 取得了很好的性能; 但是操作比较复杂, 评分函数也只针对二元关系。

SimplE (Simple Enhancement of Canonical Polyadic)^[223] 和 ComplEx 都是运用二元关系的约束条件进行运算, 难以用等价的运算方式将其扩展到超关系数据中。DistMult 只针对对称关系, 难以建模反对称、逆、组合关系, 不能完全表达知识图谱。为此, Fatemi 等^[188] 使用特定位置的卷积滤波器表示实

体, 针对所有关系类型进行建模, 实现了性能的极大提升。GETD (GEneralized Tensor Decomposition)^[224] 结合 Tucker 分解和 Tensor Ring 分解, 将核心张量分解为 k 个三阶张量 (k 大于超边大小 n), 能完全表达所有关系类型, 在满足性能的同时减少模型的复杂性。

4) 基于神经网络的知识超图表示。

基于神经网络的模型能够学习实体之间的交互信息、图的拓扑结构信息等, 在关系建模、结构建模等方面提升了表示学习的性能, 包括基于 CNN 的模型以及基于 GNN 的模型等。

基于 CNN 的模型集中于学习一个超关系事实内实体之间的交互信息。NaLP (N-ary Link Prediction)^[225-226] 等都是采用卷积以及全连接网络对超关系事实进行学习, 但是表示性能较差。HINGE (Hyper-relational knowledge Graph Embedding)^[227] 则采用 2D 卷积学习超关系事实, 该模型相较于 NeuInfer 实现了性能的极大提升。

基于 GNN 的模型结合关系建模与图结构信息的学习, 极大提升了知识超图表示学习的性能。Zhang 等^[216] 采用 GAT 学习超关系事实, 但是忽略了关系的语义信息。Galkin 等^[228] 采用 GCN 学习目标实体的多跳领域信息, 在学习关系重要性的同时, 学习图的结构信息。

当前, 知识超图领域亟待解决的难题是超边大小不定问题, 即超关系事实中 n 不定。相关模型解决该问题的思路以及存在的问题如表 17 所示。

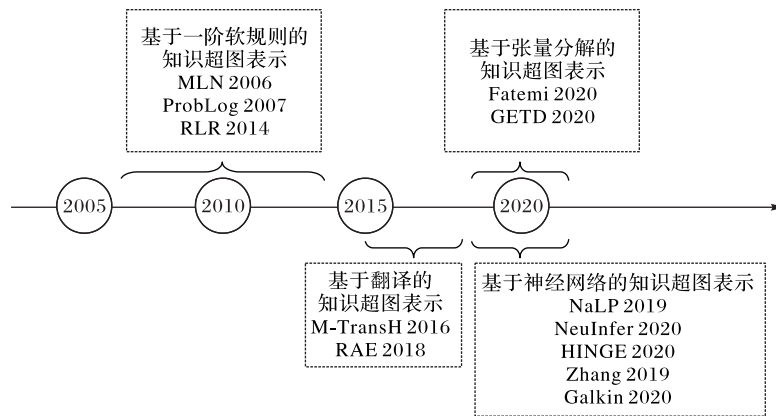


图 11 知识超图表示的主要模型

Fig. 11 Main models of knowledge hypergraph representation

表 17 知识超图表示方法对比

Tab. 17 Comparison of knowledge hypergraph representation methods

类型	具体方法	核心思路	存在问题
基于软规则	MLN ^[89] 、ProbLog ^[220] 、RLR 等 ^[221]	通过挖掘图谱中软规则, 处理可变的超关系, 具有可解释性	学习能力有限
基于翻译	M-TransH ^[187] 、RAE 等 ^[222]	通过将实体映射到关系相关的超平面, 处理可变的超关系, 且操作较简单	关系表达能力受限
基于张量分解	Fatemi 等 ^[188] GETD 等 ^[224]	通过构造固定位置的卷积滤波器, 处理可变的超关系 通过降低核心张量阶数, 降低计算复杂性, 处理可变的超关系	与实体位置强相关 模型参数较多、计算复杂度高
基于神经网络	NaLP ^[225] 、NeuInfer ^[226] 、HINGE 等 ^[227] Zhang 等 ^[216] Galkin 等 ^[228]	通过取相关性矩阵每列最小值, 处理可变的超关系 通过图神经网络的向量相加操作, 处理可变的超关系 通过图神经网络的向量相加操作, 处理可变的超关系	只能学习单个超关系事实的信息 忽略关系的语义 计算复杂度高

5.3 知识超图三层架构

现有知识超图普遍采用扁平化的结构组织知识, 缺乏时空性的表达, 导致其时空关系模糊, 知识更新与推理速度慢。因此, 本文提出知识超图三层架构, 实现事理知识、概念知识、

实例知识以及时空性的联合表达, 如图 12 所示。其显著优点包括: 1) 时空关系清晰明确; 2) 知识更新全面高效; 3) 知识推理快速可靠。

知识超图三层架构形式化表示为 $G = \{L_1, L_2, L_3, R\}$, 其

中 $R = \{R_{(L_1, L_2)}, R_{(L_2, L_3)}\}$ 表示层与层之间的关系集合。第一层是事理层,由事理实体及其之间的逻辑关系组成,形式化表示为 $L_1 = \{E_{L_1}, R_{L_1}\}$,其中 E_{L_1} 表示事理实体集合, R_{L_1} 表示事理节点之间的逻辑关系集合。事理关系集合主要包括条件、组成、顺承、因果等逻辑推理关系。第二层是概念层,由概念实体以及连接任意数量概念实体的超边组成,形式化表示为 $L_2 = \{E_{L_2}, R_{L_2}\}$,其中 E_{L_2} 表示概念实体集合, R_{L_2} 表示超边集合。第三层是实例层,由实例实体以及超边组成,形式化表示为 $L_3 = \{E_{L_3}, R_{L_3}\}$,其中 E_{L_3} 表示实例实体集合, R_{L_3} 表示超边集合。

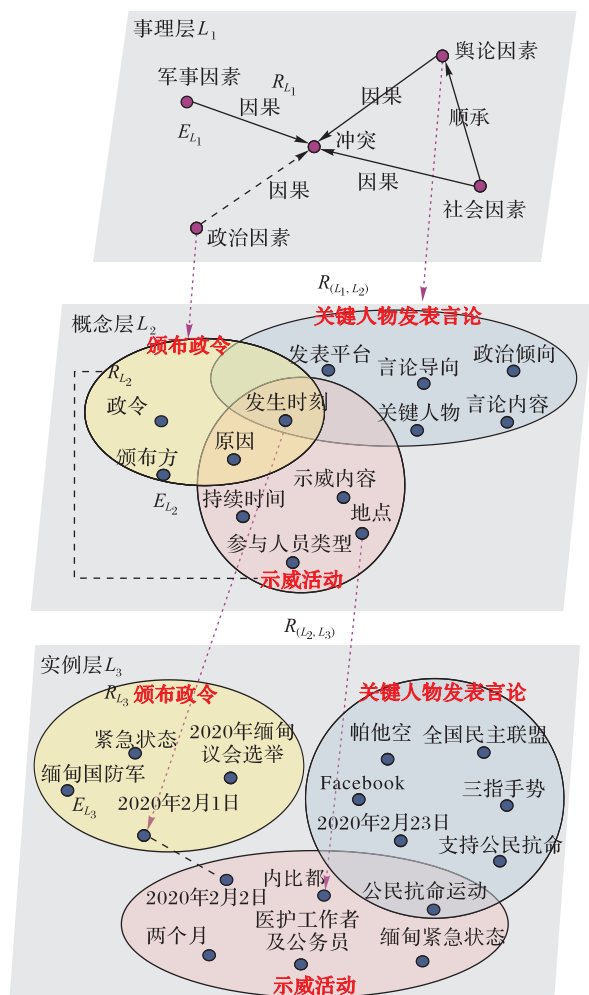


图12 知识超图的三层架构

Fig. 12 Three-layer architecture of knowledge hypergraph

事理层中节点是具有一定抽象程度的泛化事件,例如“冲突”可表示罢工、集会示威等多个具体的冲突事件。事理层节点之间的边是逻辑推理关系,例如“政治因素”“军事因素”“舆论因素”“社会因素”等共同作用会导致“冲突”的发生,因此“政治因素”等与“冲突”之间用“因果”边相连。

概念层实体是实例实体的抽象表示,表示为抽象的词,例如“地点”。概念层实体之间的边是超边,例如超边“示威活动”连接(原因,参与人员类型,发生时刻,地点,示威内容,持续时间)多个实体,能清晰表示概念实体之间的相关性。

实例层实体是描述现实世界的具体表示,例如“内比都”。实例层实体之间的边是超边,例如超边“示威活动”连接(缅甸紧急状态,医护工作者及公务员,2021年2月2日,内比都,公

民抗命运动,两个月)多个实例实体。

事理层与概念层之间的跨层关系表示事理节点与概念层超边之间的关系,例如,事理层节点“冲突”对应于概念层的超边“示威活动”。概念层与实例层之间的关系是概念实体与实例实体之间的映射关系,例如,概念实体“地点”与实例实体“内比都”之间是映射关系。

为了发现超图中的隐式关联,实现深度推理,创新性地提出了时刻与时间两个属性,表达知识超图的时空特性。其中,“时刻”属性实体表示实体或超关系在特定时间点产生或发生。例如概念层的“发生时刻”以及实例层的“2020年2月2日”。“时间”属性实体表示实体或超边在特定时间间隔内发生或是有效的。例如概念层的“持续时间”以及实例层的“两个月”。根据时空特性,可以实现隐式关联发现。例如只根据概念层“颁布政令”超边与“示威活动”超边信息,难以推理出其之间的相关性;但是根据实例层“2020年2月1日”与“2020年2月2日”在时间轴上的前后关联关系,可以推理出“颁布政令”与“示威活动”之间可能具有因果关联。

在三层架构中,通过层次之间的映射关系,例如概念实体“发生时刻”与实例实体“2020年2月2日”的映射,能实现知识的相互补充;并且根据这种映射关系,能够在知识超图中快速定位新知识,提高知识更新速度。通过概念层和实例层的时空性表达,例如“2020年2月1日”和“2020年2月2日”,可以发现“颁布政令”与“示威活动”之间的隐式关联,实现深度推理。基于此隐式关联发现,进而可以推理“政治因素”与“冲突”之间的因果关系,实现事件推理。通过层次之间信息的补充以及时空性表达,能缩减推理的查询空间,从而提高知识推理速度。

6 典型应用

随着人工智能推理需求不断增强,知识图谱及超图在许多领域得到了广泛应用。

6.1 应用方向

知识图谱及超图的应用主要集中在语义搜索、知识问答、推荐与决策等方面。

6.1.1 语义搜索

语义搜索旨在从语义层次上理解用户的检索需求,寻找与之匹配的资源。比如在使用搜索引擎搜索“缅甸的首都”时,返回结果中排首位的是“内比都”。

语义搜索包括基于文档的信息检索和基于知识图谱的语义搜索。基于文档的信息检索属于轻量级语义搜索,通常采用字面值——对应或字符串相似度等资源召回方式。其缺点是无法处理同名、别名和复杂情形。基于知识图谱的语义搜索属于重量级语义搜索,能够对语义进行显式和形式化建模。传统的语义搜索引擎,采用将问题拆分成关键词、使用限定符号等方法。基于知识图谱的语义搜索能处理更加复杂的问题,而无需采用以上方法,并且能够更清晰地理解用户的查询意图,返回相关度高、质量好的资源,使得语义搜索在工业界及学术界的优势越发显著。

6.1.2 知识问答

知识问答(Knowledge Base Question Answering, KBQA)是一种将问题带入知识库寻求答案的问答系统。知识问答能将用户输入的问题转换为客观世界的实体,而非抽象的字符串。即将自然语言问题通过不同的方法映射为结构化查询,然后在知识图谱中获取答案。

知识问答包括基于语法规则的问答和基于知识图谱的问

答。传统的问答系统基于大量的语法规则,由于缺乏泛化能力,在搭建新领域问答系统时,需要重新定义规则。基于知识图谱的问答提供了实体之间详细的关系,有助于进一步实现隐式推理,提高问答质量,提高问答速度,适应更通用的场景,使推理具有更强的解释性。未来,基于知识图谱的问答系统可以实现从单轮问答到多轮交互。

6.1.3 推荐与决策

推荐系统是解决信息过载的一个有效方法,可以向没有明确目的的用户推荐可能感兴趣的项目列表。基于知识图谱的方法能够实现个性化推荐,并且使推荐具有可解释性。

传统的推荐系统主要考虑用户序列偏好,却忽略了用户细致偏好,如用户具体喜欢哪个物品的哪些属性等;而知识图谱提供了实体与实体之间更深层次、更长范围的关联,增强了推荐算法的挖掘能力,提高了准确性和多样性,并可以有效弥补交互信息的稀疏或缺失(冷启动问题)。

决策系统主要以决策主题为中心,通过构建决策主题相关知识库、模型库和研究方法库,为决策主题提供全方位、多层次的决策支持和知识服务。知识图谱可以帮助决策沉淀出规则,提高决策模型的准确性和关联性。

6.2 应用领域

知识图谱及超图能够更加快速、高效地处理多源异构数据,并进行关联分析,已在军事、医疗、交通、金融等众多领域得到广泛应用。本节将介绍知识图谱及超图在特定领域的相关应用。

6.2.1 军事领域

随着战场信息化水平不断提高,传统的信息搜索和查询方式已经无法满足大量战场信息和军事知识的获取与分析需求。构建基于军事信息库的知识图谱,可以为作战指挥人员提供更加精确的情报,极大地提高部队作战效率。

基于军事知识图谱,建立军事武器问答系统和联合作战信息服务系统,可以实现军事辅助决策。未来,军事知识图谱能够提供大规模自主知识约束空间解决方案及智慧指挥决策解决方案,在虚拟情报参谋、隐含知识发现、情报智能关联等场景中发挥重要作用,提升部队作战能力。

6.2.2 医疗领域

智能医疗的关键是从海量、异构、动态的医疗系统中提取有效的医学知识,通过整合临床医学数据,建立医疗知识图谱,实现核心医学概念的全方位覆盖以及临床医学知识的高效分类整理和规范化表达。

知识图谱具有更接近于人类的认知思维模式,能够提高医疗信息系统的智能化水平,为医疗领域提供了从海量的医学文本和图像信息中抽取结构化知识的手段。基于医疗知识图谱,可以实现医疗知识问答、智能辅助诊疗、医疗质量控制及疾病风险评估等,具有广阔的发展前景。

6.2.3 交通领域

随着城市规模迅速扩张,交通线路规模不断庞大,空中交通流量大幅增多,公共交通所占比重不断增加。交通知识图谱可以实现交通流量分析建模、航空交通管理以及公共场景挖掘等。

交通知识图谱可以实现同乘人员识别提取、公交站点群出行量和运力挖掘、最大公交客流提取识别、线路站点上下车客流提取等,为公共交通领域提供了有效的决策和参考。未来,随着无人驾驶技术的普及,智能交通概念深入城市轨道交通与公路系统,交通知识图谱将支撑交通部门决策,生成动态交通信息对事故进行实时预警、规避交通风险。

6.2.4 金融领域

由于投资的高风险性,金融行业需要更为准确和可靠的实时数据。知识图谱作为数据驱动的人工智能,能够存储金融资讯、行情等海量数据中包含的实体、关系和属性。

金融知识图谱可以实现金融咨询推荐,风险控制评估,依据生成资讯的多维智能标签,精准掌握复杂信息中的隐藏风险。通过获取开源信息,基于知识图谱中大量金融资讯的关联信息,识别命名实体并提取相关股票之间的业务往来关系,并结合相关股票的新闻,预测股票走势。未来,基于知识图谱的金融数据平台,在信息隐含关联挖掘方面有着不可替代的能力,促进金融升级转型。

6.2.5 其他领域

除此以外,知识图谱在教育、通信等领域也有广泛应用,比如学科问答机器人、通信故障定位分析、网络安全监测等。

目前,大规模知识图谱在智能语义搜索、知识问答、演化分析、对话理解等方面的应用处于初级阶段,潜在应用领域广泛,推广前景广阔。从知识图谱应用发展趋势来看,当前正值通用知识图谱应用转向领域知识图谱应用的阶段。

6.3 未来方向

在未来,无论是军用还是民用领域,融合知识图谱与深度学习技术已成为人工智能进一步发展的重要思路。

在知识表示方面,通过研究事理逻辑知识的表示,描述事件之间的模式和演化规律。在知识推理方面,使用类似于图网络的统一框架,提高推理效率;通过结合逻辑规则和概率图等,实现更快、更准、更全且解释性更强的推理。在应用方面,基于大规模的非结构化数据自动构建知识图谱,使其具有较强的可拓展性。此外,研究包含时空属性的动态知识图谱,可以解决传统知识表示与推理的局限性问题。

总体而言,知识图谱将赋能认知智能,具有广泛且多样的应用需求,能够产生巨大社会价值,对社会结构产生深远影响。

7 结语

知识图谱突破了传统的数据存储及使用方式,以图结构呈现各类领域知识,为人工智能技术发展和模型推理提供了坚实的知识支撑。本文对知识图谱和知识超图的研究工作和应用现状进行了阐述、分析和总结,从知识图谱基本概念出发,系统地介绍了知识表示与存储方式、知识图谱构建技术、知识推理方法和知识超图表示方法。创新性提出三层架构的知识超图,表示真实世界中各类复杂知识关系,实现逻辑结构清晰、时空关系明确的知识快速推理。此外,结合技术研究进展,介绍了知识图谱和知识超图的实际应用,并作出展望。希望综述内容能够为知识图谱和知识超图领域研究提供理论指导和创新思路。

参考文献 (References)

- [1] Wikipedia. Google Knowledge Graph [EB/OL]. [2021-02-14]. https://en.wikipedia.org/wiki/Google_Knowledge_Graph.
- [2] SINGHAL A. Introducing the knowledge graph: things, not strings [EB/OL]. [2020-01-09]. <https://www.blog.google/products/search/introducing-knowledge-graph-things-not/>.
- [3] MILLER G A. WordNet: a lexical database for English [J]. Communications of the ACM, 1995, 38(11): 39-41.
- [4] SPEER R, CHIN J, HAVASI C. ConceptNet 5.5: an open multilingual graph of general knowledge [C]// Proceedings of the 31st AAAI Conference on Artificial Intelligence. Palo Alto, CA: AAAI Press, 2017:4444-4451.

- [5] BOLLACKER K, COOK R, TUFTS P. Freebase: a shared database of structured general human knowledge [C]// Proceedings of the 22nd AAAI Conference on Artificial Intelligence. Palo Alto, CA: AAAI Press, 2007: 1962-1963.
- [6] Wikidata. Main Page of Wikidata [EB/OL]. [2020-11-11]. https://www.wikidata.org/wiki/Wikidata:Main_Page.
- [7] NIU X, SUN X R, WANG H F, et al. Zhishi. me — weaving Chinese linking open data [C]// Proceedings of the 2011 International Semantic Web Conference, LNCS 7032. Berlin: Springer, 2011: 205-220.
- [8] XU B, XU Y, LIANG J Q, et al. CN-DBpedia: a never-ending Chinese knowledge extraction system [C]// Proceedings of the 2017 International Conference on Industrial, Engineering and Other Applications of Applied Intelligent Systems, LNCS 10351. Cham: Springer, 2017: 428-438.
- [9] 星河. “星河”军事知识图谱 [EB/OL]. [2020-08-01]. <https://starkg.starsee.cn/>. (StarSee. Starkg [EB/OL]. [2020-08-01]. <https://starkg.starsee.cn/>.)
- [10] IBM. Watson Health 医疗保健数据分析的重要性 [EB/OL]. [2021-03-15]. <https://www.ibm.com/cn-zh/watson-health/learn/healthcare-data-analytics>. (IBM. Watson Health - healthcare data analytics [EB/OL]. [2021-03-15]. <https://www.ibm.com/cn-zh/watson-health/learn/healthcare-data-analytics>.)
- [11] 海致星图. 海致星图金融知识图谱 [EB/OL]. [2021-03-05]. <https://www.stargraph.cn/technology.html>. (StarGraph. StarGraph financial knowledge graph [EB/OL]. [2021-03-05]. <https://www.stargraph.cn/technology.html>.)
- [12] 海信 网络科技. 交管云脑 [EB/OL]. [2021-03-01]. https://www.hisense-transtech.com.cn/Urban_Transport/Solution/1048.html. (Hisense TransTech. Cloud brain for traffic management [EB/OL]. [2021-03-01]. https://www.hisense-transtech.com.cn/Urban_Transport/Solution/1048.html.)
- [13] SMULLYAN R M. First-Order Logic [M]. Mineola, NY: Dover Publications, 1995: 43-65.
- [14] GUPTA G. Horn logic denotations and their applications [M]// APT K R, MAREK V W, TRUSZCZYNSKI M, et al. The Logic Programming Paradigm: A 25-Year Perspective. Berlin: Springer, 1999: 127-159.
- [15] QUILLAN M R. Semantic memory [R]. Cambridge: Bolt Beranek and Newman Inc., 1966.
- [16] POST E L. Formal reductions of the general combinatorial decision problem [J]. American Journal of Mathematics, 1943, 65 (2): 197-215.
- [17] MINSKY M. A framework for representing knowledge [R]. Cambridge: Massachusetts Institute of Technology, A. I. Laboratory, 1974.
- [18] TOMKINS S S. Script theory: differential magnification of affects [J]. Nebraska Symposium on Motivation, 1978, 26: 201-236.
- [19] W3C. Extensible Markup Language (XML) [EB/OL]. [2020-10-11]. <https://www.w3.org/XML/>.
- [20] W3C. Resource Description Framework (RDF) [EB/OL]. [2020-02-25]. <https://www.w3.org/RDF/>.
- [21] W3C. RDF Schema 1.1 [EB/OL]. [2020-03-22]. <https://www.w3.org/TR/rdf-schema/>.
- [22] W3C. OWL [EB/OL]. [2020-12-11]. <https://www.w3.org/OWL/>.
- [23] The Apache Software Foundation. Apache Jena [DB/OL]. [2021-03-25]. <https://jena.apache.org/>.
- [24] Eclipse Foundation. RDF4J [DB/OL]. [2021-03-26]. <https://rdf4j.org/>.
- [25] 北京大学王选计算机研究所数据管理实验室. gStore [DB/OL]. [2021-03-01]. <http://www.gstore.cn/pcsites/index.html#/>. (PKUMOD. gStore [EB/OL]. [2021-03-01]. <http://www.gstore.cn/pcsites/index.html#/>.)
- [26] The PostgreSQL Global Development Group. PostgreSQL [DB/OL]. [2021-03-15]. <https://www.postgresql.org/>.
- [27] Oracle. MySQL [DB/OL]. [2021-03-26]. <https://www.mysql.com/>.
- [28] Neo4j. Neo4j [DB/OL]. [2021-02-26]. <https://neo4j.com/>.
- [29] The Linux Foundation. JanusGraph [DB/OL]. [2021-03-08]. <https://janusgraph.org/>.
- [30] HugeGraph. HugeGraph [DB/OL]. [2021-03-29]. <https://github.com/hugegraph/hugegraph>.
- [31] DOWNEY D, BROADHEAD M, ETZIONI O. Locating complex named entities in Web text [C]// Proceedings of the 20th International Joint Conferences on Artificial Intelligence. San Francisco: Morgan Kaufmann Publishers Inc., 2007: 2733-2739.
- [32] BIKEL D M, MILLER S, SCHWARTZ R, et al. Nymble: a high-performance learning name-finder [C]// Proceedings of the 5th Conference on Applied Natural Language Processing. Stroudsburg, PA: Association for Computational Linguistics, 1997: 194-201.
- [33] McCALLUM A, LI W. Early results for named entity recognition with conditional random fields, feature induction and web-enhanced lexicons [C]// Proceedings of the 7th Conference on Natural Language Learning at HLT-NAACL 2003. Stroudsburg, PA: Association for Computational Linguistics, 2003: 188-191.
- [34] BORTHWICK A E. A maximum entropy approach to named entity recognition [D]. New York: New York University, 1999: 18-24.
- [35] COLLOBERT R, WESTON J, BOTTOU L, et al. Natural language processing (almost) from scratch [J]. Journal of Machine Learning Research, 2011, 12: 2493-2537.
- [36] STRUBELL E, VERGA P, BELANGER D, et al. Fast and accurate entity recognition with iterated dilated convolutions [C]// Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing. Stroudsburg, PA: Association for Computational Linguistics, 2017: 2670-2680.
- [37] HUANG Z, XU W, YU K. Bidirectional LSTM-CRF models for sequence tagging [EB/OL]. (2015-08-09) [2020-12-22]. <https://arxiv.org/pdf/1508.01991.pdf>.
- [38] ŽUKOV-GREGORIČ A, BACHRACH Y, COOPE S. Named entity recognition with parallel recurrent neural networks [C]// Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics. Stroudsburg, PA: Association for Computational Linguistics, 2018: 69-74.
- [39] 杨飘, 董文永. 基于BERT嵌入的中文命名实体识别方法 [J]. 计算机工程, 2020, 46 (4): 40-45, 52. (YANG P, DONG W Y. Chinese named entity recognition method based on BERT embedding [J]. Computer Engineering, 2020, 46 (4): 40-45, 52.)
- [40] LIN B Y C, LEE D H, SHEN M, et al. TriggerNER: learning with entity triggers as explanations for named entity recognition [C]// Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. Stroudsburg, PA: Association for Computational Linguistics, 2020: 8503-8511.
- [41] SCHUTZ A, BUITELAAR P. *RelExt*: a tool for relation extraction from text in ontology extension [C]// Proceedings of the 2005 International Semantic Web Conference, LNCS 3729. Berlin: Springer, 2005: 593-606.
- [42] ZENG D J, LIU K, LAI S W, et al. Relation classification via convolutional deep neural network [C]// Proceedings of the 25th International Conference on Computational Linguistics: Technical Papers. Dublin: Dublin City University, Association for Computational Linguistics, 2014: 2335-2344.

- [43] NGUYEN T H, GRISHMAN R. Relation extraction: perspective from convolutional neural networks [C]// Proceedings of the 1st Workshop on Vector Space Modeling for Natural Language Processing. Stroudsburg, PA: Association for Computational Linguistics, 2015: 39-48.
- [44] KUANG J, CAO Y X, ZHENG J B, et al. Improving neural relation extraction with implicit mutual relations [C]// Proceedings of the IEEE 36th International Conference on Data Engineering. Piscataway: IEEE, 2020: 1021-1032.
- [45] SOCHER R, HUVAL B, MANNING C D, et al. Semantic compositionality through recursive matrix-vector spaces [C]// Proceedings of the 2012 Joint Conference on Empirical Methods in Natural Language Processing and Computational Natural Language Learning. Stroudsburg, PA: Association for Computational Linguistics, 2012: 1201-1211.
- [46] XU Y, MOU L L, LI G, et al. Classifying relations via long short term memory networks along shortest dependency paths [C]// Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing. Stroudsburg, PA: Association for Computational Linguistics, 2015: 1785-1794.
- [47] GENG Z Q, CHEN G F, HAN Y M, et al. Semantic relation extraction using sequential and tree-structured LSTM with attention [J]. Information Sciences, 2020, 509: 183-192.
- [48] SHEN Y T, HUANG X J. Attention-based convolutional neural network for semantic relation extraction [C]// Proceedings of the 26th International Conference on Computational Linguistics: Technical Papers. [S. l.]: The COLING 2016 Organizing Committee, 2016: 2526-2536.
- [49] LIN Y K, SHEN S Q, LIU Z Y, et al. Neural relation extraction with selective attention over instances [C]// Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics. Stroudsburg, PA: Association for Computational Linguistics, 2016: 2124-2133.
- [50] JI G L, LIU K, HE S Z, et al. Distant supervision for relation extraction with sentence-level attention and entity descriptions [C]// Proceedings of the 31st AAAI Conference on Artificial Intelligence. Palo Alto, CA: AAAI Press, 2017: 3060-3066.
- [51] LI Y, LONG G D, SHEN T, et al. Self-attention enhanced selective gate with entity-aware embedding for distantly supervised relation extraction [C]// Proceedings of the 34th AAAI Conference on Artificial Intelligence. Palo Alto, CA: AAAI Press, 2020: 8269-8276.
- [52] ZHANG Y H, QI P, MANNING C D. Graph convolution over pruned dependency trees improves relation extraction [C]// Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing. Stroudsburg, PA: Association for Computational Linguistics, 2018: 2205-2215.
- [53] GUO Z J, ZHANG Y, LU W. Attention guided graph convolutional networks for relation extraction [C]// Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics. Stroudsburg, PA: Association for Computational Linguistics, 2019: 241-251.
- [54] SAHU S K, THOMAS D, CHIU B, et al. Relation extraction with self-determined graph convolutional network [C]// Proceedings of the 29th ACM International Conference on Information and Knowledge Management. New York: ACM, 2020: 2205-2208.
- [55] WU Y, BAMMAN D, RUSSELL S. Adversarial training for relation extraction [C]// Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing. Stroudsburg, PA: Association for Computational Linguistics, 2017: 1778-1783.
- [56] WANG X Z, HAN X, LIN Y K, et al. Adversarial multi-lingual neural relation extraction [C]// Proceedings of the 27th International Conference on Computational Linguistics. Stroudsburg, PA: Association for Computational Linguistics, 2018: 1156-1166.
- [57] 冯冲, 康丽琪, 石戈, 等. 融合对抗学习的因果关系抽取 [J]. 自动化学报, 2018, 44(5): 811-818. (FENG C, KANG L Q, SHI G, et al. Causality extraction with GAN [J]. Acta Automatica Sinica, 2018, 44(5): 811-818.)
- [58] QIN P D, XU W R, WANG W Y. DSGAN: generative adversarial training for distant supervision relation extraction [C]// Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics. Stroudsburg, PA: Association for Computational Linguistics, 2018: 496-505.
- [59] QIN P D, XU W R, WANG W Y. Robust distant supervision relation extraction via deep reinforcement learning [C]// Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics. Stroudsburg, PA: Association for Computational Linguistics, 2018: 2137-2147.
- [60] TAKANOBU R, ZHANG T Y, LIU J X, et al. A hierarchical framework for relation extraction with reinforcement learning [C]// Proceedings of the 33rd AAAI Conference on Artificial Intelligence. Palo Alto, CA: AAAI Press, 2019: 7072-7079.
- [61] XIAO Y, TAN C X, FAN Z J, et al. Joint entity and relation extraction with a hybrid transformer and reinforcement learning based model [C]// Proceedings of the 34th AAAI Conference on Artificial Intelligence. Palo Alto, CA: AAAI Press, 2020: 9314-9321.
- [62] MIWA M, BANSAL M. End-to-end relation extraction using LSTMs on sequences and tree structures [C]// Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics. Stroudsburg, PA: Association for Computational Linguistics, 2016: 1105-1116.
- [63] ZHENG S, WANG F, BAO H, et al. Joint extraction of entities and relations based on a novel tagging scheme [C]// Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics. Stroudsburg, PA: Association for Computational Linguistics, 2017: 1227-1236.
- [64] ZHENG S C, HAO Y X, LU D Y, et al. Joint entity and relation extraction based on a hybrid neural network [J]. Neurocomputing, 2017, 257: 59-66.
- [65] 陈仁杰, 郑小盈, 祝永新. 融合实体类别信息的实体关系联合抽取方法 [J/OL]. 计算机工程. (2021-03-25) [2021-05-28]. <https://doi.org/10.19678/j.issn.1000-3428.0060745>. (CHEN R J, ZHENG X Y, ZHU Y X. Joint entity and relation extraction via fusing entity type information [J/OL]. Computer Engineering. (2021-03-25) [2021-05-28]. <https://doi.org/10.19678/j.issn.1000-3428.0060745>.)
- [66] NAYAK T, NG H T. Effective modeling of encoder-decoder architecture for joint entity and relation extraction [C]// Proceedings of the 34th AAAI Conference on Artificial Intelligence. Palo Alto, CA: AAAI Press, 2020: 8528-8535.
- [67] RAJU S, PINGALI P, VARMA V. An unsupervised approach to product attribute extraction [C]// Proceedings of the 2009 European Conference on Information Retrieval, LNCS 5478. Berlin: Springer, 2009: 796-800.
- [68] SHINZATO K, SEKINE S. Unsupervised extraction of attributes and their values from product description [C]// Proceedings of the 6th International Joint Conference on Natural Language Processing. Stroudsburg, PA: Association for Computational Linguistics, 2013: 1339-1347.
- [69] ZHAO G, ZHANG T, WANG C X, et al. Applications of BERT based sequence tagging models on Chinese medical text attributes extraction [EB/OL]. (2020-08-22) [2020-12-11]. <https://arxiv>.

- org/pdf/2008.09740.pdf.
- [70] JIANG M, SHANG J B, CASSIDY T, et al. MetaPAD: meta pattern discovery from massive text corpora [C]// Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. New York: ACM, 2017: 877-886.
- [71] LOGAN R L IV, HUMEAU S, SINGH S. Multimodal attribute extraction [C]// Proceedings of the 6th Workshop on Automated Knowledge Base Construction at NIPS 2017. Red Hook, NY: Curran Associates Inc., 2017: No. 19.
- [72] COHEN W W, RICHMAN J. Learning to match and cluster large high-dimensional data sets for data integration [C]// Proceedings of the 8th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. New York: ACM, 2002: 475-480.
- [73] SUN Z Q, HU W, ZHANG Q H, et al. Bootstrapping entity alignment with knowledge graph embedding [C]// Proceedings of the 27th International Joint Conferences on Artificial Intelligence. Palo Alto, CA: AAAI Press, 2018: 4396-4402.
- [74] ZHANG Q H, SUN Z Q, HU W, et al. Multi-view knowledge graph embedding for entity alignment [C]// Proceedings of the 28th International Joint Conferences on Artificial Intelligence. Palo Alto, CA: AAAI Press, 2019: 5429-5435.
- [75] TRISEDDYA B D, QI J Z, ZHANG R. Entity alignment between knowledge graphs using attribute embeddings [C]// Proceedings of the 33rd AAAI Conference on Artificial Intelligence. Palo Alto, CA: AAAI Press, 2019: 297-304.
- [76] 车超, 刘迪. 利用双向对齐和属性信息的跨语言实体对齐 [J/OL]. 计算机工程. (2021-03-23) [2021-05-31]. <https://doi.org/10.19678/j.issn.1000-3428.0060540>. (CHE C, LIU D. Cross-language entity alignment combined with attribute information through bidirectional alignment [J/OL]. Computer Engineering. (2021-03-23) [2021-05-31]. <https://doi.org/10.19678/j.issn.1000-3428.0060540>.)
- [77] ZUHEROS C, TABIK S, VALDIVIA A, et al. Deep recurrent neural network for geographical entities disambiguation on social media data [J]. Knowledge-Based Systems, 2019, 173: 117-127.
- [78] GANEA O E, HOFMANN T. Deep joint entity disambiguation with local neural attention [C]// Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing. Stroudsburg, PA: Association for Computational Linguistics, 2017: 2619-2629.
- [79] ZHU G G, IGLESIAS C A. Exploiting semantic similarity for named entity disambiguation in knowledge graphs [J]. Expert Systems with Applications, 2018, 101: 8-24.
- [80] 张晟旗, 王元龙, 李茹, 等. 基于局部注意力机制的中文短文本实体链接 [J/OL]. 计算机工程. (2020-11-19) [2021-05-31]. <https://doi.org/10.19678/j.issn.1000-3428.0059493>. (ZHANG S Q, WANG Y L, LI R, et al. Entity linking based on local attention mechanism for Chinese short text [J]. Computer Engineering. (2020-11-19) [2021-05-31]. <https://doi.org/10.19678/j.issn.1000-3428.0059493>.)
- [81] BECHHOFFER S, HORROCKS I, GOBLE C, et al. OilEd: a reasonable ontology editor for the semantic web [C]// Proceedings of the 2001 Annual Conference on Artificial Intelligence, LNCS 2174. Berlin: Springer, 2001: 396-408.
- [82] ARPÍREZ J C, CORCHO O, FERNÁNDEZ-LÓPEZ M, et al. WebODE: a scalable workbench for ontological engineering [C]// Proceedings of the 1st International Conference on Knowledge Capture. New York: ACM, 2001: 6-13.
- [83] SURE Y, ERDMANN M, ANGELE J, et al. OntoEdit: collaborative ontology development for the semantic Web [C]// Proceedings of the 2002 International Semantic Web Conference, LNCS 2342. Berlin: Springer, 2002: 221-235.
- [84] NOY N F, FERGERTSON R W, MUSEN M A. The knowledge model of Protégé-2000: combining interoperability and flexibility [C]// Proceedings of the 2000 International Conference on Knowledge Engineering and Knowledge Management, LNCS 1937. Berlin: Springer, 2000: 17-32.
- [85] McBRIDE B. Jena: a semantic Web toolkit [J]. IEEE Internet Computing, 2002, 6(6): 55-59.
- [86] RICHARDSON S D, DOLAN W B, VANDERWENDE L. MindNet: acquiring and structuring semantic information from text [C]// Proceedings of the 36th Annual Meeting of the Association for Computational Linguistics/ 17th International Conference on Computational Linguistics. Stroudsburg, PA: Association for Computational Linguistics, 1998: 1098-1102.
- [87] ZENG X R, HE S Z, LIU K, et al. Large scaled relation extraction with reinforcement learning [C]// Proceedings of the 32nd AAAI Conference on Artificial Intelligence. Palo Alto, CA: AAAI Press, 2018: 5658-5665.
- [88] FENG J, HUANG M L, ZHAO L, et al. Reinforcement learning for relation classification from noisy data [C]// Proceedings of the 32nd AAAI Conference on Artificial Intelligence. Palo Alto, CA: AAAI Press, 2018: 5779-5786.
- [89] RICHARDSON M, DOMINGOS P. Markov logic networks [J]. Machine Learning, 2006, 62(1/2): 107-136.
- [90] PUJARA J, MIAO H, GETOOR L, et al. Knowledge graph identification [C]// Proceedings of the 2013 International Semantic Web Conference. Berlin: Springer, 2013: 542-557.
- [91] KUŽELKA O, DAVIS J. Markov logic networks for knowledge base completion: a theoretical analysis under the MCAR assumption [C]// Proceedings of the 35th Uncertainty in Artificial Intelligence Conference. New York: JMLR. org, 2020: 1138-1148.
- [92] LEE T W, LEWICKI M S, GIROLAMI M, et al. Blind source separation of more sources than mixtures using overcomplete representations [J]. IEEE Signal Processing Letters, 1999, 6(4): 87-90.
- [93] HALASCHEK-WIENER C, PARSIA B, SIRIN E, et al. Description logic reasoning for dynamic ABoxes [C]// Proceedings of the 2006 International Workshop on Description Logic. Aachen: CEUR-WS. org, 2006: No. 27.
- [94] CALVANESE D, DE GIACOMO G, LEMBO D, et al. Epistemic first-order queries over description logic knowledge bases [C]// Proceedings of the 2006 International Workshop on Description Logics. Aachen: CEUR-WS. org, 2006: No. 17.
- [95] LI Y H, XU B W, LU J J, et al. Discrete tableau algorithms for *FSHI* [C]// Proceedings of the 2006 International Workshop on Description Logics. Aachen: CEUR-WS. org, 2006: No. 14.
- [96] STOILLOS G, STAMOULIS G, PAN J Z, et al. Reasoning with very expressive fuzzy description logics [J]. Journal of Artificial Intelligence Research, 2007, 30: 273-320.
- [97] KRÖTZSCH M, MARX M, OZAKI A, et al. Attributed description logics: reasoning on knowledge graphs [C]// Proceedings of the 27th International Joint Conference on Artificial Intelligence. Palo Alto, CA: AAAI Press, 2018: 5309-5313.
- [98] 胡博, 王智学, 董庆超, 等. 基于描述逻辑的上下文知识获取与推理方法 [J]. 计算机科学, 2013, 40(4): 199-203. (HU B, WANG Z X, DONG Q C, et al. Context-aware knowledge acquisition and reasoning based on description logic [J]. Computer Science, 2013, 40(4): 199-203.)
- [99] BIENVENU M, BOURGAUX C, GOASDOUÉ F. Computing and explaining query answers over inconsistent DL-Lite knowledge bases [J]. Journal of Artificial Intelligence Research, 2019, 64: 563-644.

- [100] SCHOENMACKERS S, DAVIS J, ETZIONI O, et al. Learning first-order Horn clauses from Web text [C]// Proceedings of the 2010 Conference on Empirical Methods on Natural Language Processing. Stroudsburg, PA: Association for Computational Linguistics, 2010: 1088-1098.
- [101] LANDWEHR N, KERSTING K, DE RAEDT L. nFOIL: integrating naïve Bayes and FOIL [C]// Proceedings of the 20th National Conference on Artificial Intelligence. Palo Alto, CA: AAAI Press, 2005: 795-800.
- [102] LANDWEHR N, PASSERINI A, DE RAEDT L, et al. Fast learning of relational kernels [J]. Machine Learning, 2010, 78 (3): 305-342.
- [103] GALÁRRAGA L A, TEFLIOUDI C, HOSE K, et al. AMIE: association rule mining under incomplete evidence in ontological knowledge bases [C]// Proceedings of the 22nd International Conference on World Wide Web. New York: ACM, 2013: 413-422.
- [104] GALÁRRAGA L, TEFLIOUDI C, HOSE K, et al. Fast rule mining in ontological knowledge bases with AMIE+ [J]. The VLDB Journal, 2015, 24(6): 707-730.
- [105] WANG Z C, LI J Z. RDF2Rules: learning rules from RDF knowledge bases by mining frequent predicate cycles [EB/OL]. (2015-12-24) [2021-03-21]. <https://arxiv.org/pdf/1512.07734.pdf>.
- [106] TANON T P, STEPANOVA D, RAZNIEWSKI S, et al. Completeness-aware rule learning from knowledge graphs [C]// Proceedings of the 2017 International Semantic Web Conference, LNCS 10587. Cham: Springer, 2017: 507-525.
- [107] OMRAN P G, WANG K W, WANG Z. Scalable rule learning via learning representation [C]// Proceedings of the 27th International Joint Conference on Artificial Intelligence. Palo Alto, CA: AAAI Press, 2018: 2149-2155.
- [108] 李智星,任诗雅,王化明,等. 基于非结构化文本增强关联规则的知识推理方法[J]. 计算机学报, 2019, 46(11):209-215. (LI Z X, REN S Y, WANG H M, et al. Knowledge reasoning method based on unstructured text-enhanced association rules [J]. Computer Science, 2019, 46(11): 209-215.)
- [109] LAO N, MITCHELL T, COHEN W W. Random walk inference and learning in a large scale knowledge base [C]// Proceedings of the 2011 Conference on Empirical Methods in Natural Language Processing. Stroudsburg, PA: Association for Computational Linguistics, 2011: 529-539.
- [110] LAO N, MINKOV E, COHEN W W. Learning relational features with backward random walks [C]// Proceedings of the 53rd Annual Meeting of the Association for Computational Linguistics/ the 7th International Joint Conference on Natural Language Processing. Stroudsburg, PA: Association for Computational Linguistics, 2015: 666-675.
- [111] WANG Q, LIU J, LUO Y F, et al. Knowledge base completion via coupled path ranking [C]// Proceedings of the 54th Annual Meeting of the Association for Computational Linguistic. Stroudsburg, PA: Association for Computational Linguistics, 2016: 1308-1318.
- [112] 陈钦况,陈珂,伍赛,等. 关于主动学习下的知识图谱补全研究[J]. 计算机科学与探索, 2020, 14(5):769-782. (CHEN Q K, CHEN K, WU S, et al. Research about knowledge graph completion based on active learning [J]. Journal of Frontiers of Computer Science and Technology, 2020, 14(5):769-782.)
- [113] 刘知远,孙茂松,林衍凯,等. 知识表示学习研究进展[J]. 计算机研究与发展, 2016, 53(2): 247-261. (LIU Z Y, SUN M S, LIN Y K, et al. Knowledge representation learning: a review [J]. Journal of Computer Research and Development, 2016, 53 (2):247-261.)
- [114] GARDNER M, MITCHELL T. Efficient and expressive knowledge base completion using subgraph feature extraction [C]// Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing. Stroudsburg, PA: Association for Computational Linguistics, 2015: 1488-1498.
- [115] LIU Q, JIANG L Y, HAN M H, et al. Hierarchical random walk inference in knowledge graphs [C]// Proceedings of the 39th International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2016: 445-454.
- [116] 刘峤,韩明皓,江浏祎,等. 基于双层随机游走的关系推理算法[J]. 计算机学报, 2017, 40(6):1275-1290. (LIU Q, HAN M H, JIANG L Y, et al. Two-tier random walk based relational inference algorithm [J]. Chinese Journal of Computers, 2017, 40 (6):1275-1290.)
- [117] NICKEL M, TRESP V, KRIEGEL H P. A three-way model for collective learning on multi-relational data [C]// Proceedings of the 28th International Conference on Machine Learning. Madison, WI: Omnipress, 2011:809-816.
- [118] NICKEL M, TRESP V. Tensor factorization for multi-relational learning [C]// Proceedings of the 2013 Joint European Conference on Machine Learning and Knowledge Discovery in Databases, LNCS 8190. Berlin: Springer, 2013:617-621.
- [119] NICKEL M, TRESP V, KRIEGEL H P. Factorizing YAGO: scalable machine learning for linked data [C]// Proceedings of the 21st International Conference on World Wide Web. New York: ACM, 2012:271-280.
- [120] RENDLE S, SCHMIDT-THIEME L. Pairwise interaction tensor factorization for personalized tag recommendation [C]// Proceedings of the 3rd ACM International Conference on Web Search and Data Mining. New York: ACM, 2010:81-90.
- [121] RENDLE S. Scaling factorization machines to relational data [J]. Proceedings of the VLDB Endowment, 2013, 6(5):337-348.
- [122] JENATTON R, LE ROUX N, BORDES A, et al. A latent factor model for highly multi-relational data [C]// Proceedings of the 25th International Conference on Neural Information Processing Systems. Red Hook, NY: Curran Associates Inc. , 2012:3167-3175.
- [123] BORDES A, WESTON J, COLLOBERT R, et al. Learning structured embeddings of knowledge bases [C]// Proceedings of the 25th AAAI Conference on Artificial Intelligence. Palo Alto, CA: AAAI Press, 2011:301-306.
- [124] BORDES A, USUNIER N, GARCIA-DURÁN A, et al. Translating embeddings for modeling multi-relational data [C]// Proceedings of the 26th International Conference on Neural Information Processing Systems. Red Hook, NY: Curran Associates Inc. , 2013:2787-2795.
- [125] XIAO H, HUANG M L, ZHU X Y. From one point to a manifold: knowledge graph embedding for precise link prediction [C]// Proceedings of the 25th International Joint Conference on Artificial Intelligence. Palo Alto, CA: AAAI Press, 2016:1315-1321.
- [126] FENG J, HUANG M L, WANG M D, et al. Knowledge graph embedding by flexible translation [C]// Proceedings of the 15th International Conference on Principles of Knowledge Representation and Reasoning. Palo Alto, CA: AAAI Press, 2016:557-560.
- [127] QIAN W, FU C, ZHU Y, et al. Translating embeddings for knowledge graph completion with relation attention mechanism [C]// Proceedings of the 27th International Joint Conference on Artificial Intelligence. Palo Alto, CA: AAAI Press, 2018:4286-

- 4292.
- [128] XIAO H, HUANG M L, YU H, et al. TransA: an adaptive approach for knowledge graph embedding [EB/OL]. (2015-09-28) [2020-08-11]. <https://arxiv.org/pdf/1509.05490.pdf>.
- [129] WANG Z, ZHANG J W, FENG J L, et al. Knowledge graph embedding by translating on hyperplanes [C]// Proceedings of the 28th AAAI Conference on Artificial Intelligence. Palo Alto, CA: AAAI Press, 2014:1112-1119.
- [130] LIN Y K, LIU Z Y, SUN M S, et al. Learning entity and relation embeddings for knowledge graph completion [C]// Proceedings of the 29th AAAI Conference on Artificial Intelligence. Palo Alto, CA: AAAI Press, 2015:2181-2187.
- [131] JI G L, HE S Z, XU L H, et al. Knowledge graph embedding via dynamic mapping matrix [C]// Proceedings of the 53rd Annual Meeting of the Association for Computational Linguistics/ the 7th International Joint Conference on Natural Language Processing. Stroudsburg, PA: Association for Computational Linguistics, 2015:687-696.
- [132] JI G L, LIU K, HE S Z, et al. Knowledge graph completion with adaptive transfer matrix [C]// Proceedings of the 30th AAAI Conference on Artificial Intelligence. Palo Alto, CA: AAAI Press, 2016:985-991.
- [133] 方阳,赵翔,谭真,等. 一种改进的基于翻译的知识图谱表示方法[J]. 计算机研究与发展, 2018, 55(1):139-150. (FANG Y, ZHAO X, TAN Z, et al. A revised translation-based method for knowledge graph representation [J]. Journal of Computer Research and Development, 2018, 55(1):139-150.)
- [134] HE S Z, LIU K, JI G L, et al. Learning to represent knowledge graphs with Gaussian embedding [C]// Proceedings of the 24th ACM International Conference on Information and Knowledge Management. New York: ACM, 2015:623-632.
- [135] XIAO H, HUANG M L, ZHU X Y. TransG: a generative model for knowledge graph embedding [C]// Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics. Stroudsburg, PA: Association for Computational Linguistics, 2016:2316-2325.
- [136] SUN Z Q, DENG Z H, NIE J Y, et al. Rotate: knowledge graph embedding by relational rotation in complex space [EB/OL]. (2019-02-26) [2020-05-11]. <https://arxiv.org/pdf/1902.10197.pdf>.
- [137] EBISU T, ICHISE R. TorusE: knowledge graph embedding on a Lie group [C]// Proceedings of the 32nd AAAI Conference on Artificial Intelligence. Palo Alto, CA: AAAI Press, 2018:1819-1826.
- [138] 金婧,万怀宇,林友芳. 融合实体类别信息的知识图谱表示学习[J]. 计算机工程, 2021, 47(4):77-83. (JIN J, WAN H Y, LIN Y F. Knowledge graph representation learning fused with entity category information [J]. Computer Engineering, 2021, 47(4):77-83.)
- [139] 彭敏,黄婷,田纲,等. 聚合邻域信息的联合知识表示模型[J]. 中文信息学报, 2021, 35(5):46-54. (PENG M, HUANG T, TIAN G, et al. Neighborhood aggregation for knowledge graph representation [J]. Journal of Chinese Information Processing, 2021, 35(5):46-54.)
- [140] 夏光兵,李瑞轩,辜希武,等. 融合多源信息的知识表示学习[J/OL]. 计算机科学与探索. (2021-05-26) [2021-06-01]. <http://kns.cnki.net/kcms/detail/11.5602.TP.20210525.1633.006.html>. (XIA G B, LI R X, GU X W, et al. Knowledge representation learning based on multi-source information combination [J/OL]. Journal of Frontiers of Computer Science and Technology. (2021-05-26) [2021-06-01]. <http://kns.cnki.net/kcms/detail/11.5602.TP.20210525.1633.006.html>.)
- [141] GARCÍA-DURÁN A, BORDES A, USUNIER N. Effective blending of two and three-way interactions for modeling multi-relational data [C]// Proceedings of the 2014 European Conference on Machine Learning and Knowledge Discovery in Databases, LNCS 8724. Berlin: Springer, 2014:434-449.
- [142] YANG B S, YIH S W, HE X D, et al. Embedding entities and relations for learning and inference in knowledge bases [EB/OL]. (2015-08-29) [2020-11-11]. <https://arxiv.org/pdf/1412.6575.pdf>.
- [143] 张金斗. 知识图谱分布式表示学习方法及应用研究[D]. 合肥:中国科学技术大学, 2021:24-43. (ZHANG J D. Learning methods and application of knowledge graph distributed representation [D]. Hefei: University of Science and Technology of China, 2021:24-43.)
- [144] NICKEL M, ROSASCO L, POGGIO T. Holographic embeddings of knowledge graphs [C]// Proceedings of the 30th AAAI Conference on Artificial Intelligence. Palo Alto, CA: AAAI Press, 2016:1955-1961.
- [145] TROUILLON T, WELBL J, RIEDEL S, et al. Complex embeddings for simple link prediction [C]// Proceedings of the 33rd International Conference on Machine Learning. New York: JMLR.org, 2016:2071-2080.
- [146] ZHANG S, TAY Y, YAO L N, et al. Quaternion knowledge graph embeddings [C]// Proceedings of the 33rd Conference on Neural Information Processing Systems. La Jolla, CA: Neural Information Processing Systems Foundation, 2019:2731-2741.
- [147] LIU H X, WU Y X, YANG Y M. Analogical inference for multi-relational embeddings [C]// Proceedings of the 34th International Conference on Machine Learning. New York: JMLR.org, 2017:2168-2178.
- [148] BORDES A, GLOROT X, WESTON J, et al. A semantic matching energy function for learning with multi-relational data: application to word-sense disambiguation [J]. Machine Learning, 2014, 94(2):233-259.
- [149] SOCHER R, CHEN D Q, MANNING C D, et al. Reasoning with neural tensor networks for knowledge base completion [C]// Proceedings of the 26th International Conference on Neural Information Processing Systems. Red Hook, NY: Curran Associates Inc., 2013:926-934.
- [150] DONG X, GABRILOVICH E, HEITZ G, et al. Knowledge vault: a web-scale approach to probabilistic knowledge fusion [C]// Proceedings of the 20th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. New York: ACM, 2014:601-610.
- [151] LIU Q, JIANG H, EVDOKIMOV A, et al. Probabilistic reasoning via deep learning: neural association models [EB/OL]. (2016-08-03) [2020-11-12]. <https://arxiv.org/pdf/1603.07704.pdf>.
- [152] XIE R B, LIU Z Y, JIA J, et al. Representation learning of knowledge graphs with entity descriptions [C]// Proceedings of the 30th AAAI Conference on Artificial Intelligence. Palo Alto, CA: AAAI Press, 2016:2659-2665.
- [153] SHI B X, WENINGER T. Open-world knowledge graph completion [C]// Proceedings of the 32nd AAAI Conference on Artificial Intelligence. Pal Alto, CA: AAAI Press, 2018:1957-1964.
- [154] 鲍开放,顾君忠,杨静. 基于结构与文本联合表示的知识图谱补全方法[J]. 计算机工程, 2018, 44(7):205-211. (BAO K F, GU J Z, YANG J. Knowledge graph completion method based on jointly representation of structure and text [J]. Computer Engineering, 2018, 44(7):205-211.)
- [155] ZHAO F, XU T, JIN L, et al. Convolutional network embedding

- of text-enhanced representation for knowledge graph completion [J]. *IEEE Internet of Things Journal*, 2020(Early Access): 1-1.
- [156] DETTMERS T, MINERVINI P, STENETORP P, et al. Convolutional 2D knowledge graph embeddings[C]// *Proceedings of the 32nd AAAI Conference on Artificial Intelligence*. Palo Alto, CA: AAAI Press, 2018: 1811-1818.
- [157] VASHISHTH S, SANYAL S, NITIN V, et al. InteractE: improving convolution-based knowledge graph embeddings by increasing feature interactions [C]// *Proceedings of the 34th AAAI Conference on Artificial Intelligence*. Palo Alto, CA: AAAI Press, 2020: 3009-3016.
- [158] ZHANG Z L, LI Z F, LIU H, et al. Multi-scale dynamic convolutional network for knowledge graph embedding[J]. *IEEE Transactions on Knowledge and Data Engineering*, 2020 (Early Access): 1-1.
- [159] 李少杰, 陈曙东, 郝悦星, 等. 基于卷积神经网络的高效知识表示模型[J]. *高技术通讯*, 2020, 30(9): 901-907. (LI S J, CHEN S D, HAO Y X, et al. A novel knowledge representation model based on convolutional neural network[J]. *Chinese High Technology Letters*, 2020, 30(9): 901-907.)
- [160] ANNERVAZ K M, CHOWDHURY S B R, DUKKIPATI A. Learning beyond datasets: knowledge graph augmented neural networks for natural language processing[C]// *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*. Stroudsburg, PA: Association for Computational Linguistics, 2018: 313-322.
- [161] NEELAKANTAN A, ROTH B, McCALLUM A. Compositional vector space models for knowledge base completion [C]// *Proceedings of the 53rd Annual Meeting of the Association for Computational Linguistics/ the 7th International Joint Conference on Natural Language Processing*. Stroudsburg, PA: Association for Computational Linguistics, 2015: 156-166.
- [162] DAS R, NEELAKANTAN A, BELANGER D, et al. Chains of reasoning over entities, relations, and text using recurrent neural networks [C]// *Proceedings of the 15th Conference of the European Chapter of the Association for Computational Linguistics*. Stroudsburg, PA: Association for Computational Linguistics, 2017: 132-141.
- [163] JAGVARAL B, LEE W K, ROH J S, et al. Path-based reasoning approach for knowledge graph completion using CNN-BiLSTM with attention mechanism [J]. *Expert Systems with Applications*, 2020, 142: No. 112960.
- [164] GUO L B, ZHANG Q H, GE W Y, et al. DSKG: a deep sequential model for knowledge graph completion [C]// *Proceedings of the 2018 China Conference on Knowledge Graph and Semantic Computing, CCIS 957*. Singapore: Springer, 2018: 65-77.
- [165] CHEN W R, HONG D P, ZHENG C. Learning knowledge graph embedding with entity descriptions based on LSTM networks[C]// *Proceedings of the 2020 IEEE International Symposium on Product Compliance Engineering-Asia*. Piscataway: IEEE, 2020: 1-7.
- [166] ZHAO M J, ZHAO Y W, XU B. Knowledge graph completion via complete attention between knowledge graph and entity descriptions[C]// *Proceedings of the 3rd International Conference on Computer Science and Application Engineering*. New York: ACM, 2019: No. 47.
- [167] 靳京. 基于深度学习融入实体描述的知识图谱表示学习研究[D]. 北京: 北京交通大学, 2018: 27-30. (JIN J. Research on knowledge graph representation learning incorporating entity description based on deep learning[D]. Beijing: Beijing Jiaotong University, 2018: 27-30.)
- [168] AN B, CHEN B, HAN X P, et al. Accurate text-enhanced knowledge graph representation learning[C]// *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*. Stroudsburg, PA: Association for Computational Linguistics, 2018: 745-755.
- [169] KIPF T N, WELLMING M. Semi-supervised classification with graph convolutional networks[EB/OL]. (2017-02-22) [2020-11-12]. <https://arxiv.org/pdf/1609.02907.pdf>.
- [170] SHANG C, TANG Y, HUANG J, et al. End-to-end structure-aware convolutional networks for knowledge base completion[C]// *Proceedings of the 33rd AAAI Conference on Artificial Intelligence*. Palo Alto, CA: AAAI Press, 2019: 3060-3067.
- [171] SCHLICHTKRULL M, KIPF T N, BLOEM P, et al. Modeling relational data with graph convolutional networks [C]// *Proceedings of the 2018 European Semantic Web Conference, LNCS 10843*. Cham: Springer, 2018: 593-607.
- [172] 聂斌玲. 基于图结构信息的知识表示学习方法研究[D]. 杭州: 浙江大学, 2019: 66-71. (NIE B L. Graph structure information for knowledge representation learning [D]. Hangzhou: Zhejiang University, 2019: 66-71.)
- [173] ZHANG Z, ZHUANG F Z, ZHU H S, et al. Relational graph neural network with hierarchical attention for knowledge graph completion [C]// *Proceedings of the 34th AAAI Conference on Artificial Intelligence*. Palo Alto, CA: AAAI Press, 2020: 9612-9619.
- [174] VELIČKOVIĆ P, CUCURULL G, CASANOVA A, et al. Graph attention networks [EB/OL]. (2018-02-04) [2020-11-12]. <https://arxiv.org/pdf/1710.10903.pdf>.
- [175] XU X R, FENG W, JIANG Y S, et al. Dynamically pruned message passing networks for large-scale knowledge graph reasoning[EB/OL]. (2020-04-07) [2020-11-12]. <https://arxiv.org/pdf/1909.11334.pdf>.
- [176] ZHANG Y, CHEN X, YANG Y, et al. Efficient probabilistic logic reasoning with graph neural networks [EB/OL]. [2021-01-13]. <https://arxiv.org/pdf/2001.11850.pdf>.
- [177] XIE Z W, ZHOU G Y, LIU J, et al. ReInceptionE: relation-aware inception network with joint local-global structural information for knowledge graph embedding[C]// *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*. Stroudsburg, PA: Association for Computational Linguistics, 2020: 5929-5939.
- [178] NATHANI D, CHAUHAN J, SHARMA C, et al. Learning attention-based embeddings for relation prediction in knowledge graphs [C]// *Proceedings of the 57th Conference of the Association for Computational Linguistics*. Stroudsburg, PA: Association for Computational Linguistics, 2019: 4710-4723.
- [179] 康世泽, 吉立新, 张建朋. 一种基于图注意力网络的异质信息网络表示学习框架[J]. *电子与信息学报*, 2021, 43(4): 915-922. (KANG S Z, JI L X, ZHANG J P. Heterogeneous information network representation learning framework based on

- graph attention network [J]. *Journal of Electronics and Information Technology*, 2021, 43(4): 915-922.)
- [180] XIONG W H, HOANG T, WANG W Y. DeepPath: a reinforcement learning method for knowledge graph reasoning [C]// *Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing*. Stroudsburg, PA: Association for Computational Linguistics, 2017: 564-573.
- [181] DAS R, DHULIAWALA S, ZAHEER M, et al. Go for a walk and arrive at the answer: reasoning over knowledge bases with reinforcement learning [C]// *Proceedings of the 6th Workshop on Automated Knowledge Base Construction at NIPS 2017*. Red Hook, NY: Curran Associates Inc., 2017: No. 24.
- [182] WANG Q, HAO Y S, CAO J. ADRL: an attention-based deep reinforcement learning framework for knowledge graph reasoning [J]. *Knowledge-Based Systems*, 2020, 197: No. 105910.
- [183] TIWARI P, ZHU H Y, PANDEY H M. DAPath: distance-aware knowledge graph reasoning based on deep reinforcement learning [J]. *Neural Networks*, 2021, 135: 1-12.
- [184] LI Z X, JIN X L, GUAN S P, et al. Path reasoning over knowledge graph: a multi-agent and reinforcement learning based method [C]// *Proceedings of the 2018 IEEE International Conference on Data Mining Workshops*. Piscataway: IEEE, 2018: 929-936.
- [185] WAN G J, PAN S R, GONG C, et al. Reasoning like human: hierarchical reinforcement learning for knowledge graph reasoning [C]// *Proceedings of the 29th International Joint Conference on Artificial Intelligence*. Palo Alto, CA: AAAI Press, 2020: 1926-1932.
- [186] WANG Q, JI Y D, HAO Y S, et al. GRL: knowledge graph completion with GAN-based reinforcement learning [J]. *Knowledge-Based Systems*, 2020, 209: No. 106421.
- [187] WEN J F, LI J X, MAO Y Y, et al. On the representation and embedding of knowledge bases beyond binary relations [C]// *Proceedings of the 25th International Joint Conference on Artificial Intelligence*. Palo Alto, CA: AAAI Press, 2016: 1300-1307.
- [188] FATEMI B, TASLAKIAN P, VAZQUEZ D, et al. Knowledge hypergraphs: prediction beyond binary relations [C]// *Proceedings of the 29th International Joint Conference on Artificial Intelligence*. Palo Alto, CA: AAAI Press, 2020: 2191-2197.
- [189] 龚卫华, 沈松, 裴小兵, 等. 基于位置的社交网络中双重异质社区的聚类与关联方[J]. *计算机学报*, 2020, 43(10): 1909-1923. (GONG W H, SHEN S, PEI X B, et al. Clustering and associating method of dual heterogeneous communities in location based social networks[J]. *Chinese Journal of Computers*, 2020, 43(10): 1909-1923.)
- [190] 马慧芳, 张迪, 赵卫中, 等. 基于超图随机游走标签扩充的微博推荐方法[J]. *软件学报*, 2019, 30(11): 3397-3412. (MA H F, ZHANG D, ZHAO W Z, et al. Microblog recommendation method based on hypergraph random walk tag extension [J]. *Journal of Software*, 2019, 30(11): 3397-3412.)
- [191] 苏晓萍, 楼俊钢. 结合超图投影和随机游走的个性化推荐方法[J]. *情报学报*, 2012, 31(8): 830-836. (SU X P, LOU J G. An approach for personalized recommendation via hypergraph projection and random walk [J]. *Journal of the China Society for Scientific and Technical Information*, 2012, 31(8): 830-836.)
- [192] 高晨晖, 姜晓睿, 叶政君, 等. 基于异质学术超网的文献评价[J]. *情报学报*, 2016, 35(8): 826-837. (GAO C H, JIANG X R, YE Z J, et al. Ranking scientific articles over heterogeneous academic hypernetwork [J]. *Journal of the China Society for Scientific and Technical Information*, 2016, 35(8): 826-837.)
- [193] 崔阳, 杨炳儒. 超图在数据挖掘领域中的几个应用[J]. *计算机科学*, 2010, 37(6): 220-222. (CUI Y, YANG B R. Application of hypergraph in data mining [J]. *Computer Science*, 2010, 37(6): 220-222.)
- [194] PEROZZI B, AL-REFOU R, SKIENA S. DeepWalk: online learning of social representations [C]// *Proceedings of the 20th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. New York: ACM, 2014: 701-710.
- [195] ZHOU D Y, HUANG J Y, SCHÖLKOPF B. Learning with hypergraphs: clustering, classification, and embedding [C]// *Proceedings of the 19th International Conference on Neural Information Processing Systems*. Cambridge: MIT Press, 2006: 1601-1608.
- [196] LI P, MILENKOVIC O. Inhomogeneous hypergraph clustering with applications [C]// *Proceedings of the 31st International Conference on Neural Information Processing Systems*. Red Hook, NY: Curran Associates Inc., 2017: 2305-2315.
- [197] SUN Y Z, YU Y T, HAN J W. Ranking-based clustering of heterogeneous information networks with star network schema [C]// *Proceedings of the 15th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. New York: ACM, 2009: 797-806.
- [198] HUANG Y C, LIU Q S, LV F J, et al. Unsupervised image categorization by hypergraph partition [J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2011, 33(6): 1266-1273.
- [199] YANG Y Y, DENG S C, LU J, et al. GraphLSHC: towards large scale spectral hypergraph clustering [J]. *Information Sciences*, 2021, 544: 117-134.
- [200] SUN Y Z, HAN J W, YAN X F, et al. PathSim: meta path-based top-*k* similarity search in heterogeneous information networks [J]. *Proceedings of the VLDB Endowment*, 2011, 4(11): 992-1003.
- [201] FU T Y, LEE W C, LEI Z. HIN2Vec: explore meta-paths in heterogeneous information networks for representation learning [C]// *Proceedings of the 2017 ACM Conference on Information and Knowledge Management*. New York: ACM, 2017: 1797-1806.
- [202] DU Y P, GUO W Y, LIU J X, et al. Classification by multi-semantic meta path and active weight learning in heterogeneous information networks [J]. *Expert Systems with Applications*, 2019, 123: 227-236.
- [203] DONG Y X, CHAWLA N V, SWAMI A. metapath2vec: scalable representation learning for heterogeneous networks [C]// *Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. New York: ACM, 2017: 135-144.
- [204] HUANG J, CHEN C, YE F H, et al. Hyper2vec: biased random walk for hyper-network embedding [C]// *Proceedings of the 2019 International Conference on Database Systems for Advanced Applications*, LNCS 11448. Cham: Springer, 2019: 273-277.
- [205] HUANG J, LIU X, SONG Y Q. Hyper-path-based representation

- learning for hyper-networks [C]// Proceedings of the 28th ACM International Conference on Information and Knowledge Management. New York: ACM, 2019: 449-458.
- [206] YANG D Q, QU B Q, YANG J, et al. LBSN2Vec++ : heterogeneous hypergraph embedding for location-based social networks [J]. IEEE Transactions on Knowledge and Data Engineering, 2020(Early Access): 1-1.
- [207] CHEN L X, BU C J. A reduction formula for the characteristic polynomial of hypergraph with pendant edges [J]. Linear Algebra and its Applications, 2021, 611: 171-186.
- [208] GOYAL P, FERRARA E. Graph embedding techniques, applications, and performance: a survey [J]. Knowledge-Based Systems, 2018, 151: 78-94.
- [209] CHUNG F R K. The Laplacian of a hypergraph [M]// FRIEDMAN J. Expanding Graphs (DIMACS series in Discrete Mathematics and Theoretical Computer Science 10). Providence, RI: American Mathematical Society, 1993: 21-36.
- [210] RODRÍGUEZ J A. Laplacian eigenvalues and partition problems in hypergraphs [J]. Applied Mathematics Letters, 2009, 22(6): 916-921.
- [211] FU S C, LIU W F, ZHOU Y C, et al. HpLapGCN: hypergraph p -Laplacian graph convolutional networks [J]. Neurocomputing, 2019, 362: 166-174.
- [212] CAO B, LIU N N, YANG Q. Transfer learning for collective link prediction in multiple heterogenous domains [C]// Proceedings of the 27th International Conference on Machine Learning. Madison, WI: Omnipress, 2010: 159-166.
- [213] ZHANG M H, CUI Z C, JIANG S L, et al. Beyond link prediction: predicting hyperlinks in adjacency space [C]// Proceedings of the 32nd AAAI Conference on Artificial Intelligence. Palo Alto, CA: AAAI Press, 2018: 4430-4437.
- [214] FENG Y F, YOU H X, ZHANG Z Z, et al. Hypergraph neural networks [C]// Proceedings of the 33rd AAAI Conference on Artificial Intelligence. Palo Alto, CA: AAAI Press, 2019: 3558-3565.
- [215] JIANG J W, WEI Y X, FENG Y F, et al. Dynamic hypergraph neural networks [C]// Proceedings of the 28th International Joint Conferences on Artificial Intelligence. Palo Alto, CA: AAAI Press, 2019: 2635-2641.
- [216] ZHANG R C, ZOU Y S, MA J. Hyper-SAGNN: a self-attention based graph neural network for hypergraphs [EB/OL]. [2020-11-13]. <https://openreview.net/pdf?id=ryeHuJBtPH>.
- [217] SUN X G, YIN H Z, LIU B, et al. Heterogeneous hypergraph embedding for graph classification [C]// Proceedings of the 14th ACM International Conference on Web Search and Data Mining. New York: ACM, 2021: 725-733.
- [218] YADATI N, NIMISHAKAVI M, YADAV P, et al. HyperGCN: a new method for training graph convolutional networks on hypergraphs [C]// Proceedings of the 33rd Conferences on Neural Information Processing Systems. La Jolla, CA: Neural Information Processing Systems Foundation, 2019: 1509-1520.
- [219] MIKOLOV T, CHEN K, CORRADO G, et al. Efficient estimation of word representations in vector space [EB/OL]. (2013-09-07) [2020-11-13]. <https://arxiv.org/pdf/1301.3781.pdf>.
- [220] DE RAEDT L, KIMMIG A, TOIVONEN H. ProbLog: a probabilistic Prolog and its application in link discovery [C]// Proceedings of the 20th International Joint Conferences on Artificial Intelligence. Palo Alto, CA: AAAI Press, 2007: 2468-2473.
- [221] KAZEMI S M, BUCHMAN D, KERSTINHG K, et al. Relational logistic regression [C]// Proceedings of the 14th International Conference on Principles of Knowledge Representation and Reasoning. Alto, CA: AAAI Press, 2014: 548-557.
- [222] ZHANG R C, LI J P, MEI J J, et al. Scalable instance reconstruction in knowledge bases via relatedness affiliated embedding [C]// Proceedings of the 2018 World Wide Web Conference. Republic and Canton of Geneva: International World Wide Web Conferences Steering Committee, 2018: 1185-1194.
- [223] KAZEMI S M, POOLE D. SimPLE embedding for link prediction in knowledge graphs [C]// Proceedings of the 32nd International Conference on Neural Information Processing Systems. Red Hook, NY: Curran Associates Inc., 2018: 4289-4300.
- [224] LIU Y, YAO Q M, LI Y. Generalizing tensor decomposition for n-ary relational knowledge bases [C]// Proceedings of the 2020 World Wide Web Conference. New York: ACM, 2020: 1104-1114.
- [225] GUAN S P, JIN X L, WANG Y Z, et al. Link prediction on n-ary relational data [C]// Proceedings of the 2019 World Wide Web Conference. New York: ACM, 2019: 583-593.
- [226] GUAN S P, JIN X L, GUO J F, et al. NeuInfer: knowledge inference on n-ary facts [C]// Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. Stroudsburg, PA: Association for Computational Linguistics, 2020: 6141-6151.
- [227] ROSSO P, YANG D Q, CUDRÉ -MAUROUX P. Beyond triplets: hyper-relational knowledge graph embedding for link prediction [C]// Proceedings of the 2020 World Wide Web Conference. New York: ACM, 2020: 1885-1896.
- [228] GALKIN M, TRIVEDI P, MAHESHWARI G, et al. Message passing for hyper-relational knowledge graphs [C]// Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing. Stroudsburg, PA: Association for Computational Linguistics, 2020: 7346-7359.
- TIAN Ling**, born in 1981, Ph. D., professor. Her research interests include knowledge-driven artificial intelligence, event prediction.
- ZHANG Jinchuan**, born in 1998, Ph. D. candidate. His research interests include time series analysis, knowledge graph.
- ZHANG Jinhao**, born in 1998, Ph. D. candidate. His research interests include knowledge graph, knowledge graph question answering.
- ZHOU Wangtao**, born in 1997, Ph. D. candidate. His research interests include social media analysis, event forecasting.
- ZHOU Xue**, born in 1995, Ph. D. candidate. Her research interests include knowledge graph, representation learning.